Akademia Górniczo-Hutnicza
im. Stanisława Staszica w Krakowie

Wydział Elektrotechniki, Automatyki, Informatyki i Inżynierii Biomedycznej

KATEDRA INFORMATYKI STOSOWANEJ



PRACA INŻYNIERSKA

ZUZANNA JARLACZYŃSKA

BIEGANIE I AI: INTELIGENTNE PRZEWIDYWANIE WYNIKÓW SPORTOWYCH

PROMOTOR:
prof. Jarosław Wąs

Kraków 2025

OŚWIADCZENIE AUTORA PRACY

OŚWIADCZAM, ŚWIADOMY ODPOWIEDZIALNOŚCI KARNEJ ZA POŚWIADCZENIE NIEPRAWDY, ŻE NINIEJSZĄ PRACĘ DYPLOMOWĄ WYKONAŁEM OSOBIŚCIE I SAMODZIELNIE, I NIE KORZYSTAŁEM ZE ŹRÓDEŁ INNYCH NIŻ WYMIENIONE W PRACY.

. . . . . .

PODPIS

Serdecznie dziękuję mojemu promotorowi za wsparcie w pisaniu pracy oraz znajomym z sekcji sportowych, którzy udostępnili mi swoje dane treningowe

Spis treści

1. Wstęp ... 8

1.1. Uzasadnienie wyboru tematu ... 8

1.2. Cele i zakres pracy ... 8

1.3. Struktura pracy ... 9

2. Przegląd literatury i istniejących rozwiązań ... 10

2.1. Klasyczne metody prognozowania wyników biegowych ... 10

2.2. Zastosowanie metod uczenia maszynowego w analizie sportu ... 11

2.3. Teoretyczne podstawy sieci rekurencyjnych LSTM i GRU ... 12

2.3.1. Long Short-Term Memory (LSTM) ... 12

2.3.2. Gated Recurrent Unit (GRU) ... 12

2.3.3. Architektury dwukierunkowe (Bidirectional) ... 13

2.4. Modele sekwencyjne (RNN, LSTM, GRU) w przewidywaniu wyników ... 13

2.5. Kluczowe parametry w predykcji wyników biegowych ... 14

2.6. Wnioski z analizy literatury ... 15

3. Analiza problemu i charakterystyka danych ... 19

3.1. Definicja problemu ... 19

3.2. Podejście pierwsze – model ogólny ... 19

3.3. Podejście drugie – model spersonalizowany ... 21

3.4. Porównanie zbiorów danych ... 22

3.5. Wyzwania i ograniczenia ... 22

3.6. Pozycjonowanie pracy na tle literatury ... 22

4. Etap I – Model ogólny (większy zbiór danych, mniejsza dokładność) ... 24

4.1. Założenia eksperymentu i opis celu modelu ... 24

4.2. Przygotowanie danych i preprocessing ... 24

4.2.1. Agregacja cech użytkownika ... 24

4.2.2. Detekcja i ekstrakcja wyników maratonów z danych treningowych ... 25

4.2.3. Czyszczenie danych i usuwanie anomalii ... 25

4.2.4. Kodowanie zmiennych kategorycznych ... 26

4.2.5. Przygotowanie danych sekwencyjnych ... 27
4.2.6. Podział na zbiory treningowy i testowy ... 27
4.2.7. Źródła danych ... 27
4.3. Budowa modeli predykcyjnych ... 27
4.3.1. Modele bazowe ... 27
4.3.2. Modele sekwencyjne ... 28
4.3.3. Porównanie skuteczności modeli ... 28
4.3.4. Finalny model GRU ... 29
4.3.5. Wyniki predykcji ... 30
4.4. Analiza błędów i interpretacja wyników ... 30
4.4.1. Wzór Riegela – porównanie ... 30
4.4.2. Ocena skuteczności ... 31
4.5. Wnioski ... 31
5. Etap II – Model personalizowany (mniejszy, za to bardziej dokładny zbiór danych) ... 32
5.1. Przygotowanie danych i preprocessing ... 32
5.1.1. Źródła danych ... 32
5.1.2. Identyfikacja kluczowych kolumn i ujednolicenie jednostek ... 33
5.1.3. Mapowanie typów aktywności i typów kolumn ... 33
5.1.4. Obsługa brakujących wartości i wartości skrajnych ... 33
5.1.5. Obliczanie HRMax ... 34
5.1.6. Identyfikacja biegów będących częścią triathlonu ... 34
5.1.7. Identyfikacja wyścigów ... 34
5.1.8. Proces testowania i doboru parametrów identyfikacji wyścigów ... 35
5.1.9. Przygotowanie danych sekwencyjnych ... 37
5.1.10. Podział na zbiory treningowy i testowy ... 37
5.1.11. Architektura modelu ... 38
5.1.12. Wyniki predykcji ... 40
5.1.13. Analiza błędów i interpretacja wyników ... 41
5.1.14. Wnioski ... 43
6. Analiza porównawcza modeli i wnioski końcowe ... 45
6.1. Porównanie skuteczności modelu ogólnego i personalizowanego ... 45
6.2. Porównanie z istniejącymi rozwiązaniami ... 45
6.3. Analiza wpływu cech na dokładność predykcji ... 46
6.4. Ograniczenia badawcze i problemy napotkane ... 46
6.5. Rekomendacje dla praktyków sportowych ... 47
6.6. Kierunki przyszłych badań ... 47

6.7. Podsumowanie 48

1. Wstęp

1.1. Uzasadnienie wyboru tematu

Dynamiczny rozwój technologii pomiarowych oraz popularyzacja urządzeń monitorujących aktywność fizyczną, takich jak zegarki sportowe i opaski fitness, przyczyniły się do powstania ogromnych zbiorów danych dotyczących treningów i wyników sportowych [1, 2]. Dane te, gromadzone i udostępniane m.in. przez platformy takie jak Strava, stwarzają nowe możliwości wykorzystania metod sztucznej inteligencji do analizy i prognozowania wyników sportowych. W ostatnich latach rośnie zainteresowanie zastosowaniem uczenia maszynowego i sieci neuronowych w sporcie, jednak wiele istniejących rozwiązań koncentruje się na analizie ograniczonej do profesjonalnych zawodników lub tylko prostych zależnościach statystycznych [3, 4, 5].

Wybór tematyki pracy wynika z potrzeby opracowania narzędzia, które mogłoby wspierać zarówno amatorów, jak i bardziej zaawansowanych biegaczy w planowaniu treningów oraz realistycznej ocenie wyników w nadchodzących zawodach. Połączenie analizy danych biegowych z technikami uczenia głębokiego umożliwia tworzenie modeli, które potrafią uwzględnić indywidualne cechy zawodnika, historię treningową oraz czynniki środowiskowe. Projekt ten stanowi więc połączenie praktycznego zastosowania sztucznej inteligencji z rosnącym zainteresowaniem sportami wytrzymałościowymi [6], ukazując potencjał nowoczesnych metod predykcyjnych w dziedzinie aktywności fizycznej i zdrowego stylu życia.

1.2. Cele i zakres pracy

Celem projektu Bieganie i AI: Inteligentne przewidywanie wyników sportowych jest opracowanie i porównanie dwóch podejść do prognozowania wyników biegowych z wykorzystaniem metod uczenia maszynowego i głębokiego uczenia. Pierwsze podejście ma charakter ogólny - opiera się na zbiorze danych obejmującym wielu zawodników, uwzględniając zarówno dane sekwencyjne (serie aktywności biegowych o różnej długości), jak i dane statyczne (wiek, płeć, kraj pochodzenia). W tej części pracy skupiono się na przewidywaniu wyników biegu maratońskiego, testując różne architektury sieci neuronowych (m.in. GRU i LSTM) oraz klasyczne modele uczenia maszynowego, takie jak lasy losowe i regresja liniowa. Skuteczność modeli oceniano przy użyciu metryk regresyjnych, takich jak MAE, RMSE oraz NRMSE, a także poprzez wizualizację wyników predykcji.

Drugie podejście ma charakter spersonalizowany i zostało zaprojektowane dla użytku przez konkretnego zawodnika. Model ten opiera się na szczegółowych danych treningowych eksportowanych z

platform Strava oraz Garmin Connect [7, 8], obejmujących m.in. tętno (średnie, maksymalne), tempo (średnie, maksymalne), sumaryczne przewyższenia na trasie, czas całkowity oraz czas w ruchu, a także warunki środowiskowe (temperatura). Dzięki temu możliwe jest dokładniejsze modelowanie indywidualnych cech biegacza. Co istotne, każdy użytkownik platformy Strava może wyeksportować własne dane treningowe, co pozwoli w przyszłości wykorzystać opracowany model do uzyskania spersonalizowanej predykcji czasu ukończenia biegu na dowolnym dystansie. Model ma za zadanie umożliwić określenie zarówno dystansu, na jakim odbywa się wyścig, jak i profilu trasy poprzez podanie jej całkowitego przewyższenia. W efekcie prognozowanie wyniku w konkretnych warunkach startowych może być bardziej dokładne.

W ramach pracy dokonano analizy i porównania skuteczności obu podejść, oceniając ich przydatność w kontekście praktycznego wykorzystania modeli predykcyjnych w sporcie amatorskim i profesjonalnym.

1.3. Struktura pracy

Praca składa się z sześciu głównych rozdziałów, które systematycznie prowadzą od definicji problemu badawczego do wniosków i rekomendacji praktycznych. Kolejne rozdziały prezentują się następująco:

Rozdział 2: Przegląd literatury i istniejących rozwiązań przedstawia aktualny stan wiedzy w dziedzinie prognozowania wyników sportowych. Analizuje zarówno klasyczne metody matematyczne, jak i nowoczesne podejścia oparte na uczeniu maszynowym, ze szczególnym uwzględnieniem modeli sekwencyjnych.

Rozdział 3: Analiza problemu i charakterystyka danych definiuje badany problem oraz prezentuje dwa alternatywne podejścia: model ogólny i model spersonalizowany. Zawiera szczegółową charakterystykę wykorzystanych zbiorów danych oraz identyfikuje kluczowe wyzwania i ograniczenia.

Rozdział 4: Etap I – Model ogólny dokumentuje proces budowy modelu opartego na większym zbiorze danych o mniejszej szczegółowości. Przedstawia kompletny pipeline przetwarzania danych, architekturę modeli oraz analizę uzyskanych wyników w porównaniu z tradycyjnymi metodami prognozowania.

Rozdział 5: Etap II – Model personalizowany koncentruje się na opracowaniu bardziej zaawansowanego modelu, wykorzystującego bogatsze dane treningowe poszczególnych sportowców. Szczegółowo opisuje proces przygotowania danych, identyfikacji wyścigów oraz budowy hybrydowego modelu GRU z uwzględnieniem cech statycznych.

Rozdział 6: Analiza porównawcza i wnioski końcowe zawiera systematyczne porównanie obu podejść, analizę czynników wpływających na dokładność predykcji oraz praktyczne rekomendacje dla trenerów i sportowców. Identyfikuje również ograniczenia badawcze i proponuje kierunki dalszych prac.

Każdy rozdział kończy się podsumowaniem zawierającym kluczowe wnioski, które stanowią punkt wyjścia dla kolejnych etapów badawczych. Taka struktura zapewnia logiczny przepływ od teorii przez eksperymenty do praktycznych implikacji, zachowując spójność metodologiczną w całej pracy.

2. Przegląd literatury i istniejących rozwiązań

Rozwój technologii ubieralnych (ang. wearables), systemów GPS oraz platform społecznościowych dla sportowców (takich jak Strava czy Garmin Connect) sprawił, że dostęp do dużych zbiorów danych dotyczących aktywności fizycznej stał się powszechny. W efekcie rośnie zainteresowanie wykorzystaniem metod sztucznej inteligencji i uczenia maszynowego (ML) do analizy treningów i przewidywania wyników sportowych[3, 4]. W literaturze naukowej dotyczącej prognozowania wyników biegowych można wyróżnić kilka ewoluujących podejść: od prostych modeli matematycznych [9], przez klasyczne algorytmy uczenia maszynowego [10], aż po zaawansowane, sekwencyjne modele głębokiego uczenia (Deep Learning) [4]. Prognozowania te dotyczą w znacznej mierze biegów na dystansie maratońskim, a rzadziej krótszych wyścigów.

2.1. Klasyczne metody prognozowania wyników biegowych

Pierwsze próby przewidywania wyników biegowych opierały się głównie na prostych zależnościach matematycznych pomiędzy dystansem a czasem pokonania trasy. Najbardziej znanym i nadal powszechnie używanym przykładem jest wzór Riegela [9] , opisujący logarytmiczną relację pomiędzy czasami uzyskiwanymi na różnych dystansach:

$$T_2 = T_1 \left(\frac{D_2}{D_1} \right)^{1.06}$$

gdzie T_1 i D_1 oznaczają znany czas i dystans, a T_2 i D_2 – przewidywany wynik. Model ten, choć prosty i łatwy w zastosowaniu, ma istotne ograniczenia. Nie uwzględnia on indywidualnych różnic pomiędzy zawodnikami, aktualnego obciążenia treningowego, zmienności formy ani czynników zewnętrznych (np. pogoda czy profil trasy), które mają kluczowy wpływ na skuteczność predykcji [3]. Mimo to, stanowi on ważny punkt odniesienia (tak zwany baseline) w badaniach, a jego dokładność w przypadku biegów ulicznych szacuje się na około 80% [5]. Warto jednak zauważyć, że wzór Riegela zaproponowany został na podstawie wyników topowych sportowców wyczynowych. Stosowanie go do przewidywania wyników sportowców amatorów może naturalnie nie przynieść oczekiwanej dokładności, ze względu na bardzo różny charakter zarówno samego treningu, jak i progresji wyników amatorów i profesjonalistów [11].

Inne tradycyjne podejścia bazują głównie na regresji liniowej, w której analizuje się zależności między czasem na danym dystansie a zmiennymi takimi jak wiek, płeć, wskaźnik masy ciała (BMI) czy tempo biegu na treningach. Badania Lerebourga i współautorów [10] wykazały, że nawet prosta regre-

sja liniowa, wykorzystująca czas na 10 km, BMI, wiek i płeć, pozwala uzyskać bardzo wysoką korelację ($r > 0{,}90$) pomiędzy przewidywanymi a rzeczywistymi wynikami maratończyków. Choć tego typu metody cechują się prostotą i dużą przejrzystością, ich skuteczność jest ograniczona w przypadku złożonych, nieliniowych zależności pomiędzy obciążeniem treningowym a wydolnością, co jest charakterystyczne dla danych o charakterze czasowym. Ponadto, taka metoda pozwala skutecznie przewidzieć wyniki jedynie dla bardzo konkretnego biegu, dla z góry określonego dystansu i profilu trasy.

2.2. Zastosowanie metod uczenia maszynowego w analizie sportu

Wraz z rosnącą dostępnością danych z zegarków sportowych i aplikacji treningowych, zaczęto wykorzystywać bardziej zaawansowane metody uczenia maszynowego, które są w stanie wykrywać nieliniowe zależności. Algorytmy takie jak K-Nearest Neighbors (KNN), Random Forest czy bagging zyskały popularność ze względu na swoją skuteczność, przewyższającą tradycyjne metody.

W badaniu Lerebourga [10] bezpośrednio porównano sieci neuronowe (ANN) i metodę KNN przy przewidywaniu czasu maratonu. Zastosowane dane wejściowe obejmowały czas biegu na 10 km, wskaźnik masy ciała (BMI), wiek oraz płeć. Co zaskakujące, algorytm KNN uzyskał znacząco niższy błąd bezwzględny (MAE = 2,4%) niż klasyczna sieć neuronowa (MAE = 5,6%). Autorzy zasugerowali, że wyższa skuteczność KNN w tym kontekście może wynikać z mniejszej podatności na przeuczenie przy stosunkowo małej liczbie próbek (820 biegaczy) oraz prostoty problemu, gdy dane wejściowe są dobrze zdefiniowane. Warto zauważyć, że w badaniu tym wykorzystano oficjalne rankingi Francuskiej Federacji Lekkoatletycznej - nie mamy więc do czynienia ani z szerokim przekrojem wyników, od laików po profesjonalistów, ani z niepoprawnymi danymi z zegarków czy aplikacji treningowych. Takie jednolite dane, wolne od przekłamanych wartości, niewątpliwie ułatwiają predykcje, nawet w przypadku prostych metod; jednak nie dają możliwości większej generalizacji na grupy amatorskie lub biegi inne niż maraton.

Z kolei Ruiz-Mayo i współautorzy [3] zaproponowali wykorzystanie modeli zespołowych, w szczególności baggingu (100 drzew regresyjnych), do przewidywania wyników biegaczy amatorów. Ich kluczowym wkładem było opracowanie metody ekstrakcji cech z sześciotygodniowego okresu treningowego poprzedzającego maraton. Cechy te obejmowały statystyki takie jak łączny kilometraż, najdłuższy bieg, najszybsze tempo i sumaryczne przewyższenie, wyliczone dla różnych przedziałów czasowych (tygodniowych, dwutygodniowych i całego okresu). Po rygorystycznym oczyszczeniu danych (m.in. usunięciu zawodników trenujących mniej niż 3 razy w tygodniu), model baggingu osiągnął średni błąd bezwzględny (MAE) wynoszący około 9 minut (555 sekund), a dla podzbioru biegaczy, którzy nie ulegli kontuzji, błąd ten spadł do około 7 minut (436 sekund). Badanie to wyraźnie pokazało, jak jakość i selekcja danych treningowych mają kluczowe znaczenie dla dokładności modelu.

Wyniki przytoczonych badań wskazują, że klasyczne modele ML mogą z powodzeniem wspierać analizę wyników sportowych, szczególnie gdy dane są dobrze ustrukturyzowane. Jednak w przypadku długich, sekwencyjnych dzienników treningowych, które niosą informację o zmianie formy w czasie, bardziej odpowiednie okazują się modele rekurencyjne.

2.3. Teoretyczne podstawy sieci rekurencyjnych LSTM i GRU

Tradycyjne rekurencyjne sieci neuronowe (RNN) napotykają fundamentalny problem przy uczeniu długoterminowych zależności w danych sekwencyjnych. Podczas propagacji wstecznej gradienty mogą wykładniczo zanikać lub eksplodować, co uniemożliwia efektywne uczenie się zależności występujących w długich sekwencjach [12]. Problem ten jest szczególnie istotny w kontekście danych treningowych biegaczy, gdzie wzorce przygotowań mogą rozciągać się na wiele miesięcy. Z ograniczeniem tym radzą sobie jednak specjalne rodzaje sieci rekurencyjnych: LSTM i GRU.

2.3.1. Long Short-Term Memory (LSTM)

Architektura LSTM, zaproponowana przez Hochreitera i Schmidhubera w 1997 roku [13], wprowadza mechanizm bramek (gates), który pozwala na kontrolowany przepływ informacji w czasie. Kluczowymi komponentami LSTM są:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad \text{(bramka zapominania)} \tag{2.1}$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad \text{(bramka wejścia)} \tag{2.2}$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad \text{(kandydat na stan)} \tag{2.3}$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad \text{(aktualizacja stanu)} \tag{2.4}$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad \text{(bramka wyjścia)} \tag{2.5}$$

$$h_t = o_t * \tanh(C_t) \quad \text{(wyjście)} \tag{2.6}$$

gdzie:

– f_t, i_t, o_t to bramki: zapominania, wejścia i wyjścia

– C_t to stan komórki (cell state)

– h_t to ukryty stan (hidden state)

Bramka zapominania decyduje, które informacje z poprzedniego stanu powinny zostać zachowane, co jest kluczowe dla filtrowania nieistotnych treningów w długiej historii przygotowań.

2.3.2. Gated Recurrent Unit (GRU)

GRU, zaproponowane przez autorów w 2014 roku [14], stanowi uproszczoną wersję LSTM z dwiema bramkami zamiast trzech:

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad \text{(bramka aktualizacji)} \tag{2.7}$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad \text{(bramka zapomnienia)} \tag{2.8}$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t] + b) \quad \text{(kandydat na stan)} \tag{2.9}$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad \text{(aktualizacja stanu)} \tag{2.10}$$

Zalety GRU w kontekście danych sportowych:

– Mniejsza liczba parametrów → oznacza szybsze uczenie i mniejsze ryzyko przeuczenia

– Prostsza architektura → lepsza interpretowalność

– Równie dobre wyniki przy mniejszych zbiorach danych [14]

2.3.3. Architektury dwukierunkowe (Bidirectional)

W kontekście analizy danych treningowych zastosowano dwukierunkowe warianty LSTM i GRU (BiLSTM, BiGRU) [12], które przetwarzają sekwencje w obu kierunkach:

$$h_t = [\overrightarrow{h_t}, \overleftarrow{h_t}] \tag{2.11}$$

Pozwala to na uwzględnienie zarówno przeszłych, jak i "przyszłych" (w kontekście całej sekwencji) wzorców treningowych, co jest szczególnie przydatne przy analizie cykli przygotowawczych.

2.4. Modele sekwencyjne (RNN, LSTM, GRU) w przewidywaniu wyników

Kolejnym krokiem w rozwoju metod predykcyjnych było wprowadzenie wymienionych modeli sekwencyjnych, które potrafią analizować dane uporządkowane w czasie, takie jak dzienniki treningowe. Sieci rekurencyjne (RNN) oraz ich rozwinięcia — *Long Short-Term Memory (LSTM)* i *Gated Recurrent Units (GRU)* — umożliwiają uchwycenie zależności między kolejnymi jednostkami treningowymi oraz efektami długofalowych zmian formy zawodnika.

W badaniu *Win Your Race Goal* [5] zastosowano model LSTM do prognozowania wyników biegowych na różnych dystansach, od maratonu po ultramaratony. Zbiór danych obejmował kompletne dzienniki treningowe 15 biegaczy z okresu 6 lat, łącznie ponad 15 000 aktywności biegowych. Model osiągnął dokładność 90,4% dla zbioru testowego obejmującego 60 biegów, przewyższając tym samym tradycyjne formuły, takie jak wzór Riegela (80%) czy model UltraSignup (87,5%). Autorzy wykazali, że modele LSTM skutecznie uczą się dynamiki obciążenia treningowego (Training Intensity Distribution - TID [15]), szczególnie w analizie kilku tygodni przygotowań poprzedzających start. Pozwala to na przewidzenie aktualnej dyspozycji sportowca, która może znacznie odbiegać od jego maksymalnych możliwości w szczytowej formie [16]. Istotnym problemem danych wykorzystanych do treningu modelu jest brak informacji o tętnie zawodnika, będącego jednym z kluczowych, łatwomierzalnych markerów wysiłku i przemęczenia [17].

Bezpośrednie porównanie różnych architektur sieci rekurencyjnych przeprowadzili El-Kassabi i współautorzy [4]. W swoim badaniu nad prognozowaniem wyników Maratonu Bostońskiego przeanalizowali modele RNN, LSTM i GRU. Model GRU uzyskał najlepsze rezultaty, osiągając dokładność na poziomie 90% (MAPE = 10%). Autorzy zauważyli również, że usunięcie wartości odstających (outliers) z danych treningowych znacząco poprawiło wydajność wszystkich modeli głębokiego uczenia, dla GRU

aż do dokładności na poziomie 95%. To podejście budzi jednak pewne wątpliwości z racji użycia oficjalnych wyników zawodów. Nie może być tutaj mowy o niepoprawnym oznaczeniu aktywności jako wyścig albo o błędach wynikających z nieumiejętnego obsługiwania zegarka sportowego (przekłamane dane GPS albo zły typ aktywności), jak w przypadku pracy na wyeksportowanym dzienniku treningowym zawodnika. Odrzucenie wyjątkowo dobrych lub złych wyników startowych może więc oznaczać przeznaczenie modelu jedynie do przewidywania wyników przeciętnych biegaczy, bez odpowiednio indywidualnego podejścia. Jednak nawet bardziej pesymistyczne wyniki modeli dla pełnego zbioru danych potwierdzają, że modele sekwencyjne, a w szczególności GRU, są niezwykle skuteczne w modelowaniu zmian formy w czasie, gdy dostępne są długie i kompletne dzienniki treningowe. Podsumowując, zastosowanie sieci RNN, LSTM i GRU pozwala nie tylko przewidywać wynik końcowy, ale również analizować przebieg przygotowań oraz wpływ poszczególnych parametrów treningowych na wydolność zawodnika w sposób, który jest niedostępny dla prostszych modeli.

2.5. Kluczowe parametry w predykcji wyników biegowych

Obok parametrów treningowych, takich jak dystans czy tempo, kluczowe dla prognozowania wyników biegowych są wskaźniki intensywności wysiłku oparte na fizjologii. Jak podkreśla Wang Li [17], do najważniejszych należy maksymalny pobór tlenu (VO_2max) oraz parametry tętna. VO_2max, będący z definicji maksymalną ilością tlenu wykorzystywaną przez organizm przy maksymalnej intensywności, uznawany jest za najskuteczniejszy wskaźnik wytrzymałości krążeniowo-oddechowej. Jego pomiar jest jednak problematyczny, ponieważ musi być wykonywany w warunkach laboratoryjnych. Parametr maksymalnego poboru tlenu jest więc istotny w kontekście określenia ogólnego poziomu sportowego zawodnika, lecz nie ma praktycznego zastosowania w codziennym monitorowaniu jego zmęczenia i dyspozycji.

Kolejnym istotnym wskaźnikiem metabolicznym jest stężenie kwasu mlekowego we krwi (BLA), które wzrasta wraz z narastającym zmęczeniem i ma znaczący wpływ na zdolności wysiłkowe oraz subiektywne odczucia treningowe. Próg mleczanowy, oznaczający intensywność wysiłku, przy której następuje gwałtowny wzrost stężenia mleczanów, jest kluczowym parametrem w planowaniu treningu biegaczy długodystansowych. Jednak obecne na rynku urządzenia pomiarowe nie zapewniają synchronizacji z dziennikami treningowymi zawodników, przez co dane te nie są ogólnodostępne. Dodatkowo pomiar zakwaszenia jest kosztowny i w praktyce stosowany jedynie przez profesjonalistów.

W praktyce treningowej powszechnie wykorzystuje się zamiast tego monitorowanie tętna . Podstawą jest tętno maksymalne (HRmax), szacowane według wzoru 220 - wiek, na bazie którego oblicza się procentowe obciążenie (%HRmax). Praktyczne znaczenie mają poszczególne zakresy intensywności: strefa 50-60% HRmax służy regeneracji, 60-70% to optymalny zakres spalania tłuszczu, 70-80% rozwija zdolności tlenowe i jest kluczowa dla treningu maratońskiego, 80-90% to intensywność progowa z akumulacją mleczanu, a 90-100% to trening czysto beztlenowy. W kontekście identyfikacji wysiłków startowych istotne są więc ostatnie 2 strefy, w szczególności około 90% tętna maksymalnego. Nie można również pominąć pozornie oczywistego i łatwego do zmierzenia czynnika prędkości biegu. Autor wskazuje na ścisłą korelację pomiędzy prędkością a intensywnością wysiłku, co potwierdzono w badaniach

z wykorzystaniem bieżni mechanicznej, gdzie wzrost prędkości bezpośrednio przekładał się na zwiększenie obciążenia fizjologicznego organizmu. Ostatecznie implementacja parametrów fizjologicznych (VO_2max, $HRmax$, $\%HRR$, BLA) wraz z pomiarami prędkości do modeli predykcyjnych mogłaby znacząco zwiększyć ich dokładność, pozwalając na bardziej spersonalizowane prognozowanie wyników w oparciu o rzeczywisty stan metaboliczny i wydolnościowy organizmu zawodnika. W kontekście tej pracy szczególnie ważne będą parametr tętna oraz prędkość, łatwo mierzalne przez zegarki sportowe oraz paski tętna.

2.6. Wnioski z analizy literatury

Na podstawie analizy dostępnych prac badawczych i implementacji modeli predykcyjnych w sporcie wyciągnięto następujące wnioski:

Zastosowane techniki

W literaturze dominują dwa główne podejścia do modelowania wyników sportowych:

1. **Klasyczne metody uczenia maszynowego (ML):**
   - K-Nearest Neighbors (KNN),
   - regresja liniowa i metoda Random Forest,
   - metody zespołowe, takie jak bagging
2. **Głębokie sieci neuronowe (Deep Learning):**
   - Recurrent Neural Networks (RNN),
   - Long Short-Term Memory (LSTM),
   - Gated Recurrent Unit (GRU).

Klasyczne metody charakteryzują się prostą interpretowalnością i niewielkimi wymaganiami obliczeniowymi, natomiast sieci neuronowe lepiej odwzorowują złożone, nieliniowe zależności w danych o charakterze sekwencyjnym. W najnowszych pracach obserwuje się tendencję do łączenia tych podejść – np. wykorzystania klasycznych algorytmów do wstępnej selekcji cech oraz sieci neuronowych do właściwej predykcji.

Źródła danych

Modele wykorzystują zróżnicowane źródła danych, w tym:

- publiczne rankingi i wyniki zawodów,
- dane biometryczne z zegarków sportowych i urządzeń typu *wearables*,
- indywidualne dzienniki treningowe (np. z platform Strava, TrainingPeaks, Garmin Connect).

Kluczowe znaczenie dla dokładności modeli ma jakość oraz zakres danych, obejmujących:

– historię treningową (objętość, częstotliwość i typy treningów),

– cechy fizyczne zawodnika (wiek, masa ciała, poziom wytrenowania),

– historię startów i osiągnięć,

– warunki zewnętrzne (temperatura, wilgotność, profil trasy, przewyższenia).

Badania wyraźnie wskazują, że jakość danych treningowych ma fundamentalne znaczenie dla dokładności modeli predykcyjnych. Rygorystyczne oczyszczanie danych, w tym usuwanie zawodników o nieregularnym treningu oraz eliminacja wartości odstających, może poprawić dokładność predykcji nawet o kilkanaście procent [4, 3].

Istotnym wyzwaniem pozostaje różnica w charakterystyce danych pomiędzy oficjalnymi rankingami a dziennikami treningowymi z aplikacji. Podczas gdy dane rankingowe są jednolite i wiarygodne, dzienniki treningowe często zawierają błędy pomiarowe, niepoprawnie oznaczone aktywności oraz przekłamania GPS, co wymaga zaawansowanych metod preprocessingu [5, 3]. Dostarczają jednak jednocześnie bardzo wartościowych informacji m.in. o zróżnicowaniu tętna oraz tempa zawodnika, zarówno podczas wyścigu, jak i na treningach. Takie dane nie są możliwe do uzyskania z oficjalnych rankingów, a według specjalistów stanowią kluczowy element oceny poziomu zmęczenia sportowca.

Kluczowe parametry treningowe

Analiza literatury identyfikuje istotny rozdźwięk pomiędzy parametrami fizjologicznymi a ich praktyczną dostępnością. Podczas gdy wskaźniki takie jak VO_2max czy stężenie kwasu mlekowego (BLA) są uznawane za najbardziej miarodajne [17], ich pomiar jest kosztowny i wymaga specjalistycznego sprzętu, przez co pozostają poza zasięgiem większości biegaczy amatorów.

W praktyce parametry tętna i prędkości okazują się najbardziej obiecujące dla modeli predykcyjnych, będąc jednocześnie łatwo mierzalnymi przez powszechnie dostępne zegarki sportowe. Szczególnie istotne są:

– Tętno maksymalne (HRmax) i procentowe obciążenie (%HRmax)

– Prędkość biegu jako bezpośredni wskaźnik intensywności wysiłku

– Rozkład intensywności treningowej (TID) w poszczególnych strefach tętna

Zakres dystansów w badaniach predykcyjnych

Przegląd literatury ujawnia wyraźną dominację biegów maratońskich w badaniach nad predykcją wyników biegowych. Większość analizowanych prac koncentruje się wyłącznie na dystansie 42,195 km, co z jednej strony znajduje uzasadnienie w specyfice długich dystansów - profesjonalni maratończycy startują w tym dystansie zazwyczaj tylko 2-3 razy w roku [18], co czyni każdy start wydarzeniem wymagającym szczególnego przygotowania i zwiększa wartość trafnej prognozy. Dodatkowo, dłuższe dystanse lepiej nadają się do analiz ze względu na większą stabilność tempa i mniejszy wpływ czynników losowych.

Z drugiej strony, pomijanie krótszych dystansów stanowi poważne ograniczenie, ponieważ znaczna większość biegaczy rekreacyjnych regularnie uczestniczy w biegach na 5 km, 10 km czy półmaratonach, które stanowią podstawę ich aktywności startowej. Brak modeli predykcyjnych dostosowanych do wymienionych dystansów pozostawia lukę w narzędziach treningowych dostępnych dla tej grupy.

Nieliczne prace podejmują próbę stworzenia modeli uniwersalnych, zdolnych do przewidywania wyników na różnych dystansach. Wyjątkiem jest badanie Dash [5], w którym zaproponowano uogólnione podejście do prognozowania wyników na dystansach od maratonu po ultramaratony (50 km, 80 km, 100 km, 162 km) przy użyciu modelu LSTM. Model ten, trenowany na kompletnych dziennikach treningowych, osiągnął dokładność 90,4% dla 60 różnych biegów, demonstrując tym samym zdolność do generalizacji pomiędzy różnymi dystansami.

Warto zauważyć, że brakuje kompleksowych modeli obejmujących pełne spektrum dystansów biegowych - od biegów krótkich (5 km, 10 km) przez półmaraton, maraton, aż do biegów ultra. Istniejące rozwiązania są zazwyczaj wyspecjalizowane w konkretnych przedziałach dystansów, co stanowi istotne ograniczenie dla biegaczy trenujących i ścigających się na różnych dystansach w ramach swojego rocznego cyklu startowego.

Dokładność predykcji

Porównanie skuteczności modeli wskazuje na wyraźną przewagę metod głębokiego uczenia:

– modele **GRU** osiągają skuteczność predykcji rzędu 90–95%,

– **LSTM** uzyskują wyniki w granicach 88–91%,

– klasyczne metody (np. KNN, regresja liniowa, Random Forest) – w przedziale 80–89%.

Modele sekwencyjne (LSTM, GRU) lepiej odwzorowują zmienność formy zawodnika w czasie, jednak ich skuteczność silnie zależy od dostępności dużych, dobrze przygotowanych zbiorów danych treningowych. Warto zauważyć, że prostsze metody, takie jak KNN, mogą konkurować z zaawansowanymi modelami w przypadku dobrze zdefiniowanych cech i jednolitych danych [10], także dla mniejszych zbiorów uczących.

Ograniczenia istniejących rozwiązań

Przegląd literatury ujawnia kilka istotnych ograniczeń obecnych rozwiązań:

– Brak uwzględnienia parametrów fizjologicznych w większości modeli

– Problemy z generalizacją modeli trenowanych na danych z oficjalnych rankingów

– Niedostosowanie do specyfiki biegaczy amatorów, których progresja i charakterystyka treningu znacząco różnią się od profesjonalistów

– Zależność od jakości danych, w której modele wymagają starannego czyszczenia i preprocessingu

Kierunki dalszego rozwoju

Analiza literatury pokazuje, że największy potencjał mają modele spersonalizowane, uwzględniające indywidualne cechy zawodnika, jego historię treningową oraz warunki zewnętrzne, w jakich odbywa się bieg. W przyszłości sugeruje się rozwój systemów umożliwiających:

- integrację danych z platform takich jak **Strava** czy **Garmin Connect** , z uwzględnieniem parametrów tętna,
- prognozowanie wyników z uwzględnieniem **profilu trasy** (np. płaska, pagórkowata, górska) oraz **pogody**,
- dostarczanie sportowcom praktycznych informacji dotyczących optymalnego tempa i przygotowania do zawodów.
- automatyczne wykrywanie i korektę błędów w danych treningowych,
- rozwój modeli hybrydowych łączących prostotę klasycznych algorytmów z mocą modeli sekwencyjnych.
- tworzenie uniwersalnych modeli predykcyjnych zdolnych do prognozowania wyników na różnych dystansach - od krótkich biegów (5 km, 10 km) przez półmaraton, maraton, aż do biegów ultra,

  W kontekście tej pracy szczególnie obiecujące wydaje się połączenie modeli sekwencyjnych (LSTM/GRU) z łatwo mierzalnymi parametrami (tętno, prędkość) oraz zaawansowanymi technikami czyszczenia danych treningowych, co może zapewnić dokładne prognozy dla biegaczy amatorów przy zachowaniu praktycznej stosowalności.

3. Analiza problemu i charakterystyka danych

Celem niniejszego rozdziału jest przedstawienie problemu badawczego, zakresu danych wykorzystywanych w projekcie oraz ich charakterystyki. Praca obejmuje dwa niezależne podejścia do predykcji wyników biegowych, różniące się zakresem dostępnych informacji oraz liczbą analizowanych zawodników. Pierwsze podejście opiera się na dużym zbiorze danych o ograniczonej dokładności, natomiast drugie wykorzystuje bardzo szczegółowe dane treningowe pochodzące z platform Strava oraz Garmin, dostępne jednak tylko dla mniejszej grupy sportowców.

3.1. Definicja problemu

Głównym problemem badawczym jest opracowanie modeli predykcyjnych, umożliwiających prognozowanie czasu ukończenia biegu na różnych dystansach. Ze względu na strukturę zbioru danych, w przypadku ogólnego modelu predykcje będą dotyczyć wyłącznie biegu maratońskiego. Model spersonalizowany pozwoli natomiast na wybór dystansu od 3 do 42 kilometrów. Wyzwanie polega na uwzględnieniu wielu czynników wpływających na wynik sportowy, takich jak poziom wytrenowania, objętość i intensywność treningu, cechy fizyczne zawodnika oraz warunki zewnętrzne. Dodatkową trudność stanowi nierównomierność danych — różna długość historii treningowej poszczególnych sportowców, brak części pomiarów biometrycznych oraz zróżnicowana częstotliwość rejestrowania aktywności.

3.2. Podejście pierwsze – model ogólny

Do budowy modelu ogólnego wykorzystano publiczny zbiór danych zawierający informacje o aktywnościach biegowych użytkowników, zebranych z aplikacji śledzącej treningi (Strava). Dane te obejmują zarówno parametry pojedynczych aktywności (dystans, czas trwania, tempo, liczba aktywności), jak i cechy użytkowników (wiek, płeć, kraj). Celem predykcji jest oszacowanie indywidualnego czasu ukończenia maratonu (*m_time*) na podstawie wcześniejszych danych treningowych.

Zbiór danych użyty w analizie zawiera **10 703 690 rekordów treningów biegowych** z lat **2019 i 2020**, pochodzących od przeszło **72 000 zawodników** z całego świata. Dane zostały pozyskane za pomocą techniki *web scraping* - metody automatycznego gromadzenia danych z witryn internetowych, przy użyciu odpowiednich skryptów i programów - z publicznie dostępnych profili użytkowników serwisu społecznościowego Strava, przeznaczonego dla osób uprawiających aktywność fizyczną. Ten sposób pozyskania danych nie wymaga osobistego eksportu przez użytkownika, ale nie dostarcza tym sa-

mym istotnych informacji, takich jak średnie i maksymalne tętno, które mogą być wykorzystane jako kluczowy marker poziomu wysiłku.

Każdy rekord w zbiorze danych opisuje pojedynczą aktywność biegową i zawiera następujące kolumny:

- `datetime` – data wykonania aktywności biegowej;
- `athlete` – anonimowy identyfikator zawodnika (liczba całkowita);
- `distance` – przebyty dystans w kilometrach (liczba zmiennoprzecinkowa);
- `duration` – czas trwania biegu w minutach (liczba zmiennoprzecinkowa);
- `gender` – płeć zawodnika: `M` (mężczyzna) lub `F` (kobieta);
- `age_group` – przedział wiekowy: `18 - 34`, `35 - 54` lub `55+`;
- `country` – kraj pochodzenia zawodnika;
- `major` – lista maratonów (World Marathon Majors), w których zawodnik brał udział do 2020 roku (ciąg znaków oddzielonych przecinkami).

Przedziały wiekowe przypisano na podstawie udziału zawodnika w ostatnim maratonie z serii World Marathon Majors.

Oryginalny zbiór danych został stworzony na potrzeby badania, którego celem była ocena wpływu pandemii COVID-19 na treningi biegowe na długich dystansach. Za długodystansowych biegaczy uznano użytkowników, którzy do 2019 roku mieli zarejestrowany przynajmniej jeden udział w jednym z sześciu maratonów zaliczanych do *World Marathon Majors* (Nowy Jork, Londyn, Boston, Tokio, Chicago, Berlin). Uwzględniono jedynie osoby, które udostępniły swoje dane publicznie oraz podały informacje o płci i wieku.

Kluczowym wyzwaniem w modelu ogólnym było poprawne zidentyfikowanie rzeczywistych wyników maratonów spośród wszystkich aktywności treningowych. Wykorzystano następujące kryteria:

- Aktywność musiała odbyć się w dniu oficjalnego maratonu (np. Berlin 2019: 2019-09-29)
- Dystans musiał przekraczać 42 km
- Zawodnik musiał mieć wpisany dany maraton w kolumnie `major`
- Dla zawodników z wieloma maratonami wybrano najnowszy bieg

Ostatecznie zidentyfikowano **5 234 zawodników** z potwierdzonymi wynikami maratonów.

Wszystkie dane zostały zanonimizowane, a analiza została przeprowadzona z wykorzystaniem Jupyter Notebooks w środowisku Python. Dane pozyskano w sposób zgodny z zasadami etycznymi, wyłącznie z publicznie dostępnych źródeł, bez kontaktu z użytkownikami serwisu Strava. Dokładną metodologię oraz zbiory danych można znaleźć w publikacji: Afonseca LA, Watanabe RN, Duarte M. (2022). A worldwide comparison of long-distance running training in 2019 and 2020: associated effects of the COVID-19 pandemic [19].

3.3. Podejście drugie – model spersonalizowany

Drugie podejście skupia się na budowie modelu dedykowanego pojedynczemu zawodnikowi, bazującego na szczegółowych danych treningowych eksportowanych z platform Strava i Garmin Connect. W tym przypadku dane dotyczą mniejszej liczby osób (20 sportowców, w tym zarówno amatorów, jak i profesjonalistów, zarówno kobiet, jak i mężczyzn), ale zawierają znacznie więcej informacji na temat każdej aktywności, w tym m.in.:

- dystans i czas trwania treningu,
- tempo średnie i maksymalne,
- tętno średnie i maksymalne,
- sumaryczne przewyższenie trasy oraz zmiany wysokości (Elevation Gain/Loss, Max/Min Elevation),
- liczba kroków, kadencja i długość kroku,
- moc generowana podczas aktywności (Max/Average Watts, Weighted Average Power),
- kalorie i Training Stress Score (TSS),
- warunki pogodowe i środowiskowe: temperatura, wilgotność, ciśnienie, prędkość wiatru, opady itp.
- dane sprzętowe i kontekstowe (wyposażenie, waga zawodnika, typ aktywności, notatki treningowe).

Dla Stravy typowe kolumny obejmują m.in.: `Activity ID`, `Activity Date`, `Activity Name`, `Elapsed Time`, `Distance`, `Max Heart Rate`, `Average Heart Rate`, `Elevation Gain/Loss`, `Average/Max Cadence`, `Max/Avg Watts`, `Calories`, `Temperature`, `Weather Condition`, `Total Steps`, `Training Load` i wiele innych szczegółowych parametrów aktywności.

Dla Garmina kolumny obejmują m.in.: `Typ aktywności`, `Data`, `Dystans`, `Czas`, `Średnie tętno`, `Maksymalne tętno`, `Średnie tempo`, `Najlepsze tempo`, `Całkowity wznios`, `Całkowity spadek`, `Średnia kadencja`, `Maksymalna kadencja`, `Średnia długość kroku`, `Kroki`, `Training Stress Score (TSS)`, `Minimalna i Maksymalna temperatura`, `Maksymalna i Minimalna wysokość`, `Liczba okrążeń`, `Czas najlepszego okrążenia` i inne.

W odróżnieniu od modelu ogólnego, w tym podejściu celem jest stworzenie modelu personalizowanego, który:

- przewiduje czasy ukończenia biegów na dowolnym dystansie, od 3 do 42 kilometrów,
- pozwala na rozróżnienie profilu trasy w formie podania sumarycznego przewyższenia na trasie,

– uwzględnia przewidywane warunki pogodowe (np. temperatura, wilgotność, wiatr).

– bazuje na prywatnych, dokładnych dziennikach treningowych zawodników

– stwarza możliwość budowy systemu pozwalającego na predykcję czasu wyścigu dla dowolnego zawodnika, który udostępni modelowi swoje wyeksportowane dane treningowe.

Model ten ma charakter spersonalizowany – jest trenowany indywidualnie na danych danego zawodnika, co pozwala uzyskać znacznie większą precyzję prognoz, mimo ograniczonej liczby próbek. Wykorzystuje on architekturę rekurencyjną (model GRU) do analizy sekwencji treningów oraz dodatkowych danych kontekstowych opisujących warunki startowe i charakterystykę aktywności.

3.4. Porównanie zbiorów danych

Różnice pomiędzy dwoma podejściami przedstawiono w tabeli 3.1. Każdy zbiór został przygotowany z myślą o odmiennym zastosowaniu — pierwszy do ogólnego modelowania wyników populacji biegaczy, a drugi do predykcji indywidualnej.

3.5. Wyzwania i ograniczenia

Największym wyzwaniem projektu jest zróżnicowana jakość i kompletność danych. Model ogólny pozwala na analizę szerokiego przekroju populacji biegaczy, jednak brak szczegółowych informacji fizjologicznych ogranicza jego precyzję. Z kolei model spersonalizowany wykorzystuje dane bardzo dokładne, ale liczba próbek jest niewielka, co może prowadzić do przeuczenia (ang. *overfitting*). Dodatkowym ograniczeniem jest brak standaryzacji danych eksportowanych z różnych urządzeń i platform (np. Garmin Connect, Strava), które mogą różnić się częstotliwością pomiaru oraz sposobem zapisu aktywności.

Pomimo tych trudności, oba podejścia stanowią wartościowe i komplementarne perspektywy analizy – jedno ukierunkowane na uogólnienie populacyjne, drugie na indywidualną interpretację wyników i personalizację predykcji.

3.6. Pozycjonowanie pracy na tle literatury

W odróżnieniu od przytoczonych badań, niniejsza praca:

– Łączy podejście ogólne (duży zbiór) z personalizowanym (szczegółowe dane)

– Uwzględnia dane fizjologiczne (tętno) dostępne dla biegaczy amatorskich

– Obejmuje pełne spektrum dystansów od 3 km do maratonu w modelu personalizowanym

– Zastosowuje zaawansowane techniki czyszczenia danych z platform komercyjnych

Tabela 3.1: Porównanie dwóch podejść i zbiorów danych

Cecha	**Zbiór ogólny**	**Zbiór spersonalizowany**
Źródło danych	publiczny zbiór danych	pliki .csv wyeksportowane z platform Strava/Garmin
Liczba zawodników	>72 000	20
Zakres danych	podstawowe: dystans, czas, tempo, płeć, wiek, kraj	szczegółowe: dystans, czas, tempo średnie i maksymalne, tętno średnie i maksymalne, przewyższenie, kadencja, długość kroku, moc, kalorie, Training Stress Score, warunki pogodowe, dane sprzętowe i kontekstowe
Cel modelu	przewidywanie wyniku maratonu	przewidywanie wyników na dystansach 3–42 km z uwzględnieniem profilu trasy i warunków pogodowych
Rodzaj danych	sekwencje treningów z ogólnymi danymi kontekstowymi	sekwencje treningów z dokładnymi danymi kontekstowymi
Typ modelu	regresja liniowa, Random Forest, LSTM, GRU	GRU
Zastosowanie	analiza populacyjna i uogólniona	indywidualna prognoza i personalizacja wyników

4. Etap I – Model ogólny (większy zbiór danych, mniejsza dokładność)

4.1. Założenia eksperymentu i opis celu modelu

Celem eksperymentu było opracowanie modelu predykcyjnego, który na podstawie danych treningowych umożliwia przewidywanie czasu ukończenia maratonu (*m_time*) przez zawodników. Model obejmuje dużą populację biegaczy, wykorzystując podstawowe informacje o aktywnościach biegowych, takie jak dystans, czas, tempo, liczba startów oraz cechy demograficzne (wiek, płeć, kraj).

4.2. Przygotowanie danych i preprocessing

Dane surowe zostały przefiltrowane i przekształcone w celu uzyskania reprezentacji umożliwiającej trenowanie modeli regresyjnych i sekwencyjnych. Zbiór danych obejmował łącznie 10 703 690 rekordów aktywności biegowych z lat 2019-2020 od 72 842 zawodników z całego świata. W szczególności wykonano następujące kroki:

4.2.1. Agregacja cech użytkownika

Dla każdego zawodnika obliczono statystyki opisujące aktywności w okresie poprzedzającym maraton:

- `distance_sum` – suma przebytych dystansów [km],
- `duration_sum` – suma czasów trwania aktywności [min],
- `overall_m_count` – liczba wszystkich aktywności treningowych,
- `total_days` – liczba unikalnych dni z treningami.
- `avg_pace` – średnie tempo treningowe [min/km]

Agregacje połączono następnie z informacjami demograficznymi zawodników.

4.2.2. Detekcja i ekstrakcja wyników maratonów z danych treningowych

Kluczowym wyzwaniem w przygotowaniu danych było poprawne zidentyfikowanie rzeczywistych wyników maratonów spośród wszystkich aktywności treningowych. Wymagało to opracowania zaawansowanego systemu filtrowania opartego na odpowiednich kryteriach weryfikacyjnych.

Strategia detekcji wyścigów

1. **Mapowanie dat oficjalnych maratonów**

   Stworzono słownik przypisujący nazwy maratonów do ich rzeczywistych dat przeprowadzenia:

   - BERLIN 2019: 2019-09-29
   - BOSTON 2019: 2019-04-15
   - CHICAGO 2019: 2019-10-13
   - LONDON 2019: 2019-04-28
   - NEW YORK 2019: 2019-11-03
   - TOKYO 2019: 2019-03-03
   - TOKYO 2020: 2020-03-01
   - BOSTON 2020: 2020-09-14

2. **Weryfikacja zgodności dat i dystansów**

   Dla każdej aktywności sprawdzano:

   - Czy data aktywności pokrywa się z datą oficjalnego maratonu
   - Czy dystans przekracza 42 km (dopuszczając odchylenia od dokładnego dystansu maratońskiego)
   - Czy zawodnik miał wpisany dany maraton w kolumnie `major`

3. **Obsługa zawodników z wieloma maratonami** Analiza wykazała, że 634 zawodników miało więcej niż jeden zarejestrowany maraton w badanym okresie. W takim przypadku zastosowano strategię wyboru **najnowszego maratonu** dla każdego zawodnika, co pozwoliło wykorzystać najbardziej aktualne dane treningowe prowadzące do tego wydarzenia.

4.2.3. Czyszczenie danych i usuwanie anomalii

Proces czyszczenia danych obejmował kilka etapów usuwania rekordów o niskiej jakości lub podejrzanych charakterystykach:

Filtrowanie ekstremalnych wartości

– **Maratony nierealistycznie wolne**: Usunięto wszystkie wyniki maratonów przekraczające 420 minut (7 godzin), co stanowiło 2.3% wszystkich wykrytych wyścigów

– **Nierealne tempa treningowe**: Odfiltrowano aktywności o tempie szybszym niż 2.5 min/km (podejrzenie błędów GPS) lub wolniejszym niż 10 min/km (marsz lub błąd pomiaru)

– **Zerowe dystanse**: Usunięto 0.1% rekordów z dystansem 0 km

Obsługa brakujących wartości

– Kolumna `country`: Brakujące wartości (3.2% rekordów) uzupełniono wartością "Unknown"

– Kolumna `major`: Rekordy bez wpisanych maratonów wykluczono z analizy

– Kolumna `datetime`: Nieliczne rekordy z nieprawidłowymi datami usunięto

Usunięcie wycieków danych temporalnych

Kluczowym krokiem było zapewnienie, że do predykcji wyniku maratonu wykorzystywane są wyłącznie dane poprzedzające dzień wyścigu. Wszystkie aktywności odbywające się w dniu maratonu lub po nim zostały usunięte ze zbioru treningowego.

Integracja zbiorów z różnych lat

– **Unikalne identyfikatory**: Zapewniono unikalność ID zawodników między rokiem 2019 a 2020 poprzez przesunięcie ID ze zbioru 2020 o wartość `last_athlete_id + 1`

– **Weryfikacja unikalności**: Potwierdzono brak powtarzających się ID między zbiorami

– **Łączenie danych**: Finalny zbiór zawierał 72 842 unikalnych zawodników

Statystyki finalnego zbioru

Po procesie czyszczenia i filtrowania uzyskano następujące statystyki:

– **Zawodnicy z wykrytymi maratonami**: 5 234

– **Unikalne aktywności treningowe**: 894 156

– **Średnia liczba treningów na zawodnika**: 171

– **Zakres czasowy danych**: marzec 2018 - wrzesień 2020

Dzięki rygorystycznemu procesowi czyszczenia i weryfikacji udało się zbudować wysokiej jakości zbiór danych, który stanowił solidną podstawę do trenowania modeli predykcyjnych.

4.2.4. Kodowanie zmiennych kategorycznych

Zmiennym kategorycznym, takim jak płeć (`gender`), grupa wiekowa (`age_group`) oraz kraj pochodzenia (`country`), przypisano reprezentację numeryczną metodą one-hot encoding.

4.2.5. Przygotowanie danych sekwencyjnych

Do trenowania modeli sekwencyjnych (LSTM, GRU) dane zorganizowano w formie szeregów czasowych:

– każdy zawodnik jest reprezentowany jako sekwencja treningów uporządkowanych chronologicznie.

– każda próbka zawiera cechy aktywności: dystans, czas, tempo oraz datę,

– wartości znormalizowano do zakresu [0, 1] przy użyciu MinMaxScaler.

– uwzględniono tylko sekwencje zawierające co najmniej 20 aktywności.

Krótsze sekwencje zostały uzupełnione zerami (padding), a podczas treningu zastosowano maskowanie zerowe.

4.2.6. Podział na zbiory treningowy i testowy

Dane podzielono w proporcji 80:20, z zachowaniem separacji na poziomie zawodników (aby uniknąć wycieku danych między zbiorami treningowym a testowym). Ostateczny zbiór, po zastosowaniu filtru minimum 20 aktywności prowadzących do wyścigu, zawierał ponad 14000 sekwencji.

4.2.7. Źródła danych

Dane pochodzą z otwartych repozytoriów:

– `https://github.com/BMClab/covid19/` [1]

– `https://doi.org/10.7717/peerj.13192` [2]

Oryginalny zbiór danych został zgromadzony w celu analizy wpływu pandemii COVID-19 na treningi biegowe na całym świecie. Skrypty przetwarzania danych znajdują się w notatniku: `https://www.kaggle.com/code/zuskakluska/marathon-project` [20].

4.3. Budowa modeli predykcyjnych

W celu predykcji czasu ukończenia maratonu (`m_time`) zbudowano kilka modeli regresyjnych, zarówno klasycznych, jak i głębokich. Dane wejściowe obejmowały zagregowane informacje o użytkownikach, takie jak: całkowity przebyty dystans i czas (`distance_sum`, `duration_sum`), liczba przebytych maratonów (`overall_m_count`), liczba aktywnych dni (`total_days`) oraz cechy demograficzne (`gender`, `age_group`, `country`). Dane kategoryczne zostały zakodowane metodą one-hot.

4.3.1. Modele bazowe

Pierwszym modelem bazowym była regresja liniowa, której celem było określenie liniowej zależności między cechami a czasem maratonu. Model został nauczony na zbiorze treningowym (80% danych), a jakość predykcji oceniono przy użyciu metryk takich jak: MAE (średni błąd bezwzględny),

RMSE (pierwiastek błędu średniokwadratowego) oraz znormalizowany RMSE (NRMSE). Wyniki pokazały ograniczoną zdolność modelu do uchwycenia nieliniowości w danych:

– MAE: 27.98 minutes

– RMSE: 36.76 minutes

– NRMSE: 15.52%

Następnie zastosowano model Random Forest, który pozwala na modelowanie złożonych zależności nieliniowych oraz interakcji pomiędzy cechami. W porównaniu z regresją liniową, model ten uzyskał wyższą dokładność, co potwierdziły niższe wartości RMSE oraz MAE. Dla tego modelu uzyskano wyniki:

– MAE: 21.84 minutes

– RMSE: 30.15 minutes

– NRMSE: 12.73%

Dodatkowo przeanalizowano znaczenie poszczególnych cech dla predykcji, co umożliwiło lepsze zrozumienie wpływu danych wejściowych na wynik. Analiza ważności cech wykazała, że najistotniejszym predyktorem był całkowity dystans treningowy, podczas gdy całkowity czas treningu okazał się zaskakująco mało znaczący. Sugeruje to, że objętość treningowa (w kilometrach) ma większe znaczenie niż czas spędzony na treningu.

4.3.2. Modele sekwencyjne

W dalszym etapie opracowano modele głębokiego uczenia, w tym LSTM i GRU, które zostały zaprojektowane do pracy z danymi sekwencyjnymi. Zrezygnowano więc z agregacji danych, zamiast tego przekształcono dane wejściowe do formy umożliwiającej trening rekurencyjnych sieci neuronowych. Modele te składały się z warstw maskujących, warstw GRU/LSTM (również dwukierunkowych) oraz gęstych warstw w pełni połączonych. W celu redukcji przeuczenia zastosowano warstwy Dropout oraz mechanizm wczesnego zatrzymania (EarlyStopping). W przypadku modelu Bi-GRU uzyskano najlepsze wyniki, co wskazuje na zdolność głębokich sieci do uchwycenia bardziej złożonych wzorców powtarzających się w czasie.

Wszystkie modele były oceniane w sposób jednolity przy użyciu zestawu testowego oraz wspólnych metryk: MAE, RMSE, NRMSE. Analiza wyników wykazała, że modele głębokie, szczególnie Bi-GRU, oferują największy potencjał predykcyjny, jednak kosztem większej złożoności obliczeniowej oraz dłuższego czasu treningu.

4.3.3. Porównanie skuteczności modeli

Wyniki dla poszczególnych modeli przedstawiono w tabeli 4.1.

Tabela 4.1: Porównanie skuteczności różnych modeli predykcyjnych

Model	MAE [min]	RMSE [min]	NRMSE [%]
Regresja liniowa	27.98	36.76	15.52
Random Forest	21.84	30.15	12.73
LSTM	20.14	28.33	12.10
GRU 1	20.87	29.38	12.43
GRU 2	18.47	25.19	10.76
GRU 3 (finalny)	17.16	23.07	9.85

4.3.4. Finalny model GRU

W ramach eksperymentów opracowano finalną architekturę modelu rekurencyjnego opartego na warstwach GRU (Gated Recurrent Unit), zoptymalizowaną pod kątem dokładności predykcji wyników sportowych. Model przetwarza dane sekwencyjne o ustalonym kształcie `input_shape`, z obsługą różnych długości sekwencji danych poprzez warstwę maskującą.

Architektura modelu:

- **Masking** (`mask_value=0.0`): ignorowanie różnic długości sekwencji wejściowych.
- **Bidirectional GRU (64 units)** z `return_sequences=True`: dwukierunkowe przetwarzanie sekwencji, uwzględniające zarówno przeszłość, jak i przyszłość w kontekście wykrywania wzorców
- **LayerNormalization**: normalizacja cech w obrębie warstwy, wspierająca stabilność i szybkość uczenia.
- **GRU (32 units)** z `return_sequences=True`: dalsze przetwarzanie sekwencji.
- **GRU (16 units)**: wyprowadzenie końcowej reprezentacji sekwencji.
- **Dropout (rate = 0.3)**: regularyzacja, zapobiegająca przeuczeniu.
- **Dense (64 units, ReLU)**: gęsta warstwa z aktywacją ReLU.
- **Dropout (rate = 0.3)**: dodatkowa regularyzacja.
- **Dense (1 unit)**: wyjście regresyjne, przewidujące jedną wartość - czas ukończenia maratonu

Model został skompilowany z użyciem optymalizatora `Adam` (ze stopą uczenia $1 \cdot 10^{-3}$) i funkcji straty `mean squared error (MSE)`. Taka funkcja straty zapewnia odpowiednie uwzględnienie w modelu skrajnych wartości wyników zawodników, nie uśredniając tym samym predykcji na korzyść przeciętnych biegaczy. Proces trenowania wykorzystuje `EarlyStopping` z `patience=10`, przy `batch size=32` i maksymalnej liczbie epok wynoszącej 300. Model został wytrenowany na sekwencjach treningowych 4 187 zawodników.

4.3.5. Wyniki predykcji

Po zakończeniu procesu trenowania model został oceniony na zestawie testowym, osiągając następujące wyniki:

Miara błędu	Wartość
MAE (Mean Absolute Error)	17,16
RMSE (Root Mean Squared Error)	23,07
NRMSE (Normalized RMSE)	0,0985

Tabela 4.2: Wyniki modelu GRU na zbiorze testowym

Osiągnięty współczynnik NRMSE poniżej 10% wskazuje na wysoką precyzję modelu predykcyjnego. W porównaniu do modelu Random Forest, finalny GRU osiągnął poprawę dokładności o 22.8% w MAE i 23.5% w RMSE. Jest to zatem znacząca poprawa względem wcześniejszych wersji modeli głębokich, których błąd oscylował w granicach 10,5%, i jeszcze większa w porównaniu z modelami bazowymi, gdzie błąd wahał się między 13 a 15%. Dokładność predykcji zwiększyła się tym samym o ponad 10 minut w porównaniu do regresji liniowej. Wyniki te potwierdzają efektywność zastosowania architektury GRU, wspomaganej warstwami normalizującymi i regularyzującymi, w analizie danych sekwencyjnych dotyczących aktywności sportowej.

4.4. Analiza błędów i interpretacja wyników

Analiza znaczenia cech wykazała, że najbardziej wpływowym czynnikiem jest całkowity dystans przebyty w treningach. Co ciekawe, całkowity czas treningu okazał się mniej istotny, co sugeruje, że objętość treningowa (w kilometrach) ma większe znaczenie niż czas spędzony na bieganiu. Modele sekwencyjne (LSTM, GRU) uchwyciły dodatkowe wzorce nieliniowe w danych, znacznie poprawiając dokładność predykcji w porównaniu do modeli bazowych.

4.4.1. Wzór Riegela – porównanie

Aby ocenić skuteczność powyższych modeli, porównano ich wyniki z wartościami sugerowanymi przez klasyczną metodę Riegla dla naszego rzeczywistego zbioru danych z aktywnościami treningowymi. W tym celu dla każdego sportowca wybrano najszybszy trening (o najwyższym średnim tempie) jako bazę (T_1, D_1), z którego następnie wyliczono przewidywany czas maratonu (T_2). Zawodnicy o maksymalnym tempie poniżej 2,5 min/km zostali pominięci jako błąd danych. Po podstawieniu wartości do wzoru

$$T_2 = T_1 \left(\frac{D_2}{D_1} \right)^{1.06}$$

Otrzymano następujące wyniki:

– MAE: 29.31 minut

– RMSE: 42.45 minut

– NRMSE: 17.95%

Co potwierdza znaczącą przewagę modeli uczenia maszynowego nad klasycznymi metodami heurystycznymi - finalny model GRU osiągnął o ponad 40% niższy błąd w porównaniu do formuły Riegla.

4.4.2. Ocena skuteczności

Najlepsze wyniki uzyskano dla finalnego modelu GRU (dwukierunkowego), z NRMSE poniżej 10%, co wskazuje na wysoką precyzję predykcji. W porównaniu do klasycznego wzoru Riegela, który osiągnął NRMSE 17,95%, model GRU przewyższa tradycyjne metody o prawie połowę. Pokazuje to, że nawet przy relatywnie prostym podejściu sekwencyjnym (GRU z danymi treningowymi i metadanymi), można znacząco poprawić dokładność prognozowania wyników sportowych.

Należy jednak zaznaczyć, że model ten stanowi rozwiązanie kompromisowe - oferuje szeroką zastosowalność na dużej populacji biegaczy, ale kosztem pewnych ograniczeń w dokładności wynikających z jakości dostępnych danych. Trudno mianowicie określić poziom wysiłku zawodnika bez uwzględnienia chociażby tętna średniego oraz maksymalnego, a także zróżnicowania tempa podczas biegu.

4.5. Wnioski

Modele sekwencyjne, a zwłaszcza GRU, przewyższają klasyczne wzory i modele bazowe pod względem precyzji predykcji czasu maratonu. Finalny model osiągnął NRMSE 9,85%, co oznacza znaczną poprawę dokładności i potwierdza skuteczność stosowania głębokich sieci rekurencyjnych w analizie danych treningowych biegaczy.

Do kluczowych ograniczeń modelu ogólnego należą:

– Brak danych fizjologicznych (tętno średnie i maksymalne)

– Ograniczona informacja o warunkach zewnętrznych (temperatura, całkowite przewyższenie na trasie)

– Jakość danych zależna od urządzeń treningowych użytkowników oraz ich umiejętnego używania

Otrzymane wyniki skonfrontujemy teraz z analizą dla precyzyjniejszego źródła danych, wzbogaconego o bardziej złożone cechy, tj. tętno zawodnika podczas wysiłku, zmienność tempa i tętna w czasie oraz warunki środowiskowe (temperatura, przewyższenie). Uzupełnienie danych o powyższe czynniki umożliwi budowę bardziej spersonalizowanego modelu, nieograniczonego do predykcji wyniku biegu maratońskiego.

5. Etap II – Model personalizowany (mniejszy, za to bardziej dokładny zbiór danych)

Głównym celem drugiego eksperymentu było zbudowanie modelu predykcyjnego zdolnego do przewidywania rezultatu wyścigu biegowego na dowolnym dystansie. Istotnym krokiem pośrednim było wyznaczenie przez model tempa biegu na zadanym dystansie dla konkretnego zawodnika na podstawie jego historycznych danych treningowych oraz metryk statycznych. Znany dystans i przewidywane tempo pozwala ostatecznie oszacować czas wyścigu. Założeniem pracy było, że wydolność biegowa jest wypadkową nie tylko ostatnich treningów biegowych, ale również ogólnej aktywności fizycznej, takiej jak kolarstwo, pływanie czy trening siłowy, oraz stałych cech zawodnika, na przykład doświadczenie i indywidualne maksymalne tętno.

Model został pomyślany jako narzędzie wspomagające planowanie treningów i strategii wyścigowych, umożliwiające prognozowanie tempa, jakie zawodnik może w swojej aktualnej formie utrzymać na nadchodzących zawodach.

5.1. Przygotowanie danych i preprocessing

Odpowiednie przygotowanie danych było kluczowe dla sukcesu modelu, przede wszystkim ze względu na zróżnicowanie źródeł (Strava, Garmin) oraz liczbę brakujących wartości. Konieczne było więc ujednolicenie poszczególnych plików, a także indywidualne podejście do każdej z cech i określenie jej istotności.

5.1.1. Źródła danych

Dane pochodzą z osobiście pozyskanych dzienników treningowych wyeksportowanych z platformy Strava oraz Garmin. Pliki zostały zanonimizowane i udostępnione w odpowiednich repozytoriach:

- `https://www.kaggle.com/datasets/zuskakluska/activities-garmin` [7]
- `https://www.kaggle.com/datasets/zuskakluska/strava-activities` [8]

Skrypty przetwarzania danych znajdują się w notatniku: `https://www.kaggle.com/code/zuskakluska/race-predictior-2`. [21]

5.1.2. Identyfikacja kluczowych kolumn i ujednolicenie jednostek

Dane załadowano z wielu plików CSV, osobno dla eksportów z platformy Strava i Garmin Connect, przypisując każdemu rekordowi identyfikator zawodnika (`athlete_id`). Kolejnym kluczowym etapem było ujednolicenie jednostek:

- **Dystans:** Dla aktywności pływackich (`Swim`) dokonano konwersji z metrów na kilometry, zakładając że wartości większe niż 15 oznaczają dystans w metrach.
- **Prędkość:** Zaimplementowano funkcję (`parse_avg_speed`), która konwertowała prędkość średnią i maksymalną do wspólnej jednostki – metrów na sekundę (m/s). Dla biegów przekształcano tempo z formatu min/km, a dla pływania z formatu min/100m.
- **Temperatura:** W przypadku danych Garmina, gdzie dostępne były jedynie temperatura maksymalna i minimalna, obliczono temperaturę średnią.
- **Data:** Zaimplementowano funkcję `parse_mixed_date` do obsługi zróżnicowanego formatu dat w różnych dziennikach treningowych.

Na tym etapie spośród 99 kolumn wybrano te potencjalnie wartościowe: 'Activity ID', 'Activity Date', 'Activity Type', 'Elapsed Time', 'Distance', 'Max Heart Rate', 'Average Heart Rate', 'Relative Effort', 'Athlete Weight', 'Moving Time', 'Max Speed', 'Average Speed', 'Elevation Gain', 'Elevation Loss', 'Average Temperature'.

5.1.3. Mapowanie typów aktywności i typów kolumn

W kolejnym kroku dokonano mapowania typów aktywności w zbiorach danych z Garmina i ze Stravy na ujednolicone kategorie: `Run`, `Ride`, `Swim`, oraz `Weight Training`. Ponadto wszystkie aktywności inne niż bieganie, kolarstwo, pływanie i trening siłowy zostały sklasyfikowane jako `Workout`, gdyż zakładamy, że ich znaczenie jest marginalne w kontekście przewidywania czasu wyścigu. Warto tutaj podkreślić, że duża część dzienników treningowych wykorzystanych do trenowania modelu pochodzi nie od profesjonalnych biegaczy, ale triathlonistów, kolarzy oraz biegaczy amatorów. Uwzględnienie więc innych aktywności o podobnym charakterze wydolnościowym jest niezbędne do trafnego oszacowania poziomu wytrenowania zawodnika. Również nazwy kolumn zostały ujednolicone, aby w końcu połączyć eksporty z obu źródeł w finalny zbiór danych treningowych.

5.1.4. Obsługa brakujących wartości i wartości skrajnych

Kolumny 'Athlete Weight' i 'Relative Effort', chociaż potencjalnie interesujące, zostały usunięte ze zbioru danych ze względu na braki wartości przekraczające akceptowalny próg (40% dla Relative Effort i 97% dla Athlete Weight). Brakujące wartości w kolumnach numerycznych uzupełniano medianą wyliczaną najpierw dla danego zawodnika i typu aktywności, a w przypadku dalszych braków – medianą globalną dla tego typu aktywności. Zidentyfikowano również wartości nierealistyczne, tj. średnia prędkość powyżej 8 m/s, prędkość maksymalna powyżej 15 m/s (bliskie rekordowi świata), a także usunięto

biegi poniżej 1 km, jako mało reprezentatywne, mogące zawierać błędy GPS. W ten sposób usunięto 431 aktywności.

5.1.5. Obliczanie HRMax

Kolejnym bardzo istotnym etapem przygotowania zbioru danych było wyznaczenie dla każdego zawodnika parametru tętna maksymalnego. Parametr ten stanowi odniesienie dla zakresu tętna osiągniętego na treningu i jest jednym z kluczowych czynników w szacowaniu poziomu wysiłku w trakcie jednostki [17]. Maksymalne tętno (`HRMax`) dla każdego zawodnika obliczono jako średnią z 10 najwyższych zarejestrowanych wartości tętna maksymalnego z aktywności biegowych i kolarskich. Wartości z treningów pływackich pominięto ze względu na możliwe przekłamania pomiaru tętna w wodzie. Dwaj zawodnicy bez żadnych danych o tętnie zostali usunięci ze zbioru danych, ponieważ nie jesteśmy w stanie skutecznie zidentyfikować ich maksymalnych wysiłków.

5.1.6. Identyfikacja biegów będących częścią triathlonu

W celu lepszego odwzorowania kontekstu poszczególnych treningów dodano do zbioru danych kolumnę `is_triathlon`. Jej zadaniem jest oznaczenie aktywności biegowych będących częścią triathlonu. Wartość logiczna tej zmiennej została określona na podstawie analizy kolejności aktywności w danym dniu. Dla każdego zawodnika sprawdzano, czy w dniu wykonania danej aktywności biegowej (`run`) poprzedzająca ją w danym oknie czasowym aktywność miała charakter rowerowy (`ride`). Jeśli taki warunek był spełniony, kolumna `is_triathlon` przyjmowała wartość `1`, w przeciwnym wypadku `0`. Warto zauważyć, że bieg w wyścigu triathlonowym odbywa się na końcu, więc mimo maksymalnego wysiłku zawodnika, prędkość biegu będzie naturalnie niższa, niż w przypadku samego biegu. Dodanie tej cechy pozwala modelowi na uwzględnienie specyfiki obciążeń wynikających z aktywności wielodyscyplinowych, co może poprawić trafność prognoz tempa i wydolności zawodnika. Ostatecznie w zbiorze danych zidentyfikowano 256 biegów triathlonowych, w tym aż 47 wyścigów, w których bieg był częścią triathlonu. Stanowią one prawie 1/6 wszystkich wyścigów, dlatego parametr `is_triathlon` jest niezbędny do dokładnych predykcji.

5.1.7. Identyfikacja wyścigów

Aby utworzyć zmienną docelową, konieczne było zidentyfikowanie, które aktywności biegowe są wyścigami. W tym celu zastosowano funkcję `identify_races`, która wykorzystuje kombinację indywidualnych statystyk zawodnika, cech aktywności oraz progów heurystycznych.

W pierwszym kroku, dla każdego zawodnika obliczono w oknie obejmującym ostatnie 365 dni dwie charakterystyki:

– średni dystans biegowy (`avg_distance_runner`),

– średnią prędkość biegową (`avg_speed_runner`).

Następnie oceniano każdą aktywność biegową przy użyciu następujących warunków, które łącznie tworzyły zmienną `race_score`:

– **Tętno**: średnie tętno, zgodnie z zaleceniami ekspertów [17], wyższe niż 86% tętna maksymalnego zawodnika (`HRMax`), waga 2 - dla wykrycia aktywności o wyjątkowo wysokiej intensywności

– **Dystans**: dystans większy od 40 kilometrów, waga 2 - dla wykrycia aktywności wyjątkowo długich, w szczególności maratonu, który może nie wyróżniać się np. wysokim tętnem zawodnika, ze względu na długość wysiłku

– **Prędkość**: średnia prędkość wyższa niż 140% średniej prędkości biegacza z ostatniego roku, waga 2 - zdaniem ekspertów jeden z istotnych parametrów do oceny intensywności aktywności [17], dla podkreślenia wysiłków poza strefą komfortu zawodnika

– **Typ wysiłku**: aktywność oznaczona jako część triathlonu, waga 1 - trening biegowy bezpośrednio po rowerze jest stosunkowo rzadko spotykany w zwykłym treningu (lecz nie nigdy [22]), stąd niska waga

– **Dystans typowy dla wyścigu**: dystans mieszczący się w 10% tolerancji względem jednego z najczęstszych oficjalnych dystansów (5 km, 10 km, półmaraton, maraton) waga 1 - warunek sprzyjający klasyfikacji aktywności jako wyścig, lecz podobnie jak w przypadku biegu triathlonowego, niewystarczający, by uznać aktywność za wyścig

Dodatkowo, aby wykluczyć treningi z dużą liczbą przerw, np. interwałowe, gdzie średnia prędkość może być zawyżona, aktywność musiała spełniać warunek **płynności biegu** - czyli mieć stosunek czasu całkowitego do czasu ruchu nie wyższy niż 1.1.

Wprowadzono także minimalny warunek długości - dystans aktywności wynoszący co najmniej 3 km, aby ograniczyć bardzo krótkie jednostki, często wynikające z przypadkowego włączenia aktywności lub posiadające błędy gps.

Aktywność klasyfikowana była jako wyścig (`is_race = True`), jeśli:

– była aktywnością biegową,

– miała dystans co najmniej 3 km,

– spełniała warunek płynności,

– oraz uzyskała łączny `race_score` co najmniej 2.

5.1.8. Proces testowania i doboru parametrów identyfikacji wyścigów

Proces doboru parametrów heurystycznych poprzedzony został serią eksperymentów mających na celu znalezienie optymalnego kompromisu między czułością a specyficznością algorytmu.

Dobór progu tętna

W literaturze rekomendowany próg dla intensywnych wysiłków wynosi >90% HRMax [17]. Jednak w naszym przypadku `HRMax` oznacza faktyczne, zmierzone maksymalne tętno zawodnika, które jest naturalnie niższe od teoretycznych wartości. Przeprowadzono testy z różnymi progami:

– **>90% HRMax**: Zbyt restrykcyjny próg - pomijał wiele rzeczywistych wyścigów, szczególnie na dłuższych dystansach gdzie zawodnicy utrzymują niższą intensywność; zawężał też liczbę wyścigów do mniej niż 200, co zdecydowanie negatywnie wpływało na wyniki predykcji

– **>86% HRMax**: Optymalny kompromis - wykrywał 306 wyścigów przy zachowaniu rozsądnej precyzji

– **>80% HRMax**: Zbyt niski próg - pogorszenie wyników modelu sugeruje, że próg ten wprowadzał wiele fałszywych pozytywnych identyfikacji (intensywne treningi mylone z wyścigami)

Wybrany próg 86% odpowiada w praktyce około 90% teoretycznego tętna maksymalnego, co jest zgodne z rekomendacjami literaturowymi dla wysiłków o wysokiej intensywności.

Kompensacja przez warunek dystansu

Dłuższe wyścigi, szczególnie maratony, często nie spełniają warunku wysokiego tętna ze względu na strategię tempową. Dla tych przypadków wprowadziliśmy kompensujący warunek dystansu (>40 km), który zapewnia, że długie wyścigi są prawidłowo identyfikowane nawet przy niższej intensywności.

Parametr prędkości

Za próg prędkości klasyfikującej aktywność jako wyścig uznano prędkość stanowiącą 140% średniej prędkości biegacza z ostatniego roku. Podobnie jak w przypadku progu tętna, eksperymentalnie testowano zarówno większe, jak i mniejsze wartości. Ostatecznie model dawał najlepsze rezultaty dla progu 140%. Warto zauważyć, że biegi długie (maraton), których tempo może nie odbiegać znacznie od średniej prędkości treningowych, zostaną i tak wykryte dzięki warunkowi dystansu. Wybrany próg jest więc rygorystyczny i w efekcie unikamy oznaczenia intensywnych jednostek treningowych jako wyścig.

Analiza wpływu doboru parametrów na wyniki modelu

Eksperymentalnie ustalono, że próg 86% HRMax w połączeniu z warunkiem dystansu >40 km i progiem prędkości średniej >140% rocznej średniej prędkości pozwala na identyfikację około 300 wyścigów, przy zachowaniu wysokiej jakości danych. Niższe progi zwiększały liczbę identyfikacji, ale prawdopodobnie kosztem błędnego wprowadzania do zbioru wyścigów intensywnych treningów, podczas gdy wyższe progi znacząco redukowały zbiór danych, utrudniając trening modelu. Ostateczny wybór parametrów stanowi optymalny kompromis między kompletnością zbioru danych a precyzją identyfikacji, umożliwiając efektywne trenowanie modelu przy zachowaniu wiarygodności zmiennej docelowej.

Algorytm wykrył łącznie **306 wyścigów** w całym zbiorze danych. Po identyfikacji wyścigów przeanalizowano również liczbę startów dla poszczególnych zawodników, aby zweryfikować realizm przeprowadzonej klasyfikacji. Liczby te okazały się zgodne z oczekiwaniami: od pojedynczych startów u amatorów po maksymalnie 34 starty rocznie u zawodników profesjonalnych, specjalizujących się w biegach lub triathlonie.

5.1.9. Przygotowanie danych sekwencyjnych

Dla każdego wyścigu (`is_race = True`) zbudowano sekwencję treningową, obejmującą wszystkie biegi danego zawodnika w okresie 365 dni poprzedzających wyścig. Każdy rekord w sekwencji zawierał:

– Liczbę dni do wyścigu (obliczoną na podstawie daty)

– Podstawowe metryki treningu: dystans, czas całkowity, czas ruchu, prędkość średnia i maksymalna, tętno średnie i maksymalne, suma podbiegów i zbiegów, temperatura.

Dodatkowo, dla każdego wyścigu obliczono statystyczne cechy kontekstowe z całego roku poprzedzającego:

– Łączny czas, dystans oraz liczba sesji dla pływania, kolarstwa i treningu siłowego.

– Długość doświadczenia biegowego (w latach).

– Dystans i sumę przewyższenia samego wyścigu docelowego.

– Czy wyścig docelowy jest częścią wyścigu triathlonowego (1 jeśli tak, 0 w przeciwnym wypadku)

Zmienną docelową (`y`) było tempo wyścigowe w sekundach na kilometr, obliczane jako `czas_ruchu[s]`/(`dystans[m]`/1000).

5.1.10. Podział na zbiory treningowy i testowy

Aby uniknąć wycieku danych testowych, podziału na zbiór treningowy i testowy (w proporcji 80/20) dokonano na poziomie zawodników i ich wyścigów. Dla każdego zawodnika jego najnowsze wyścigi (20%) trafiały do zbioru testowego, a starsze do treningowego. Zapewniło to, że model był testowany na **przyszłych, niewidzianych przez model** wyścigach, zachowując naturalny porządek czasowy przygotowań. Dzięki temu wyniki testowe odzwierciedlają rzeczywisty scenariusz użycia — prognozowanie tempa przed nadchodzącymi zawodami, podczas gdy znamy historię treningową zawodnika.

W przypadku dostępności większej ilości danych możliwe byłoby również zastosowanie alternatywnej strategii, polegającej na wydzieleniu całych dzienników treningowych zawodników do zbioru testowego (np. dzienniki od 20% biegaczy). Takie podejście pozwoliłoby dodatkowo ocenić zdolność modelu do generalizacji między zawodnikami, lecz przy ograniczonym rozmiarze naszego zbioru uznano, że testowanie w obrębie każdego zawodnika daje bardziej stabilne i wiarygodne rezultaty.

W kontekście nowego zawodnika, który nie występował w danych treningowych, model nadal może generować predykcje, o ile dostępna jest jego historia treningowa z ostatnich dni lub tygodni (eksport takich danych jest możliwy bezpośrednio z platformy Strava oraz Garmin Connect). Model w takim przypadku traktuje biegacza jako nowy przypadek, którego wynik przewiduje na podstawie wzorców wyuczonych na innych zawodnikach o podobnym profilu treningowym.

Ostateczny zbiór danych zawierał 300 sekwencji (242 treningowe, 58 testowych). Sekwencje ujednolicono do wspólnej długości 232 kroków czasowych (najdłuższa sekwencja w zbiorze) poprzez dopeł-

nienie wartością 999.0 (`pad_sequences`). Standardowe wypełnienie zerami nie zostało wprowadzone ze względu na binarny charakter cechy `is_triathlon`.

Wszystkie cechy numeryczne (sekwencyjne, statyczne i target) zostały przeskalowane do rozkładu normalnego (`StandardScaler`) z użyciem parametrów wyliczonych wyłącznie na zbiorze treningowym.

5.1.11. Architektura modelu

Początkowo przetestowano zarówno architekturę LSTM (Long Short-Term Memory), jak i GRU (Gated Recurrent Unit). W modelu maratońskim GRU wykazał wyraźną przewagę, osiągając NRMSE 9.85% w porównaniu do 12.10% dla LSTM, co jest zgodne z wynikami znajdowanymi w literaturze. Również w przypadku modelu personalizowanego w początkowych etapach testowania modeli GRU okazał się bardziej efektywny, co skłoniło do skupienia się na dopracowywaniu tej właśnie architektury.

Przewagi GRU w kontekście danych treningowych:

- **Mniejsza złożoność obliczeniowa**: GRU posiada tylko dwie bramki (reset i update) w porównaniu do trzech w LSTM, co przekłada się na szybsze uczenie
- **Lepsza generalizacja na małych zbiorach**: Mniejsza liczba parametrów redukuje ryzyko przeuczenia, co jest kluczowe przy ograniczonej liczbie zawodników (20)
- **Skuteczność w modelowaniu średnioterminowych zależności**: Dane treningowe charakteryzują się zależnościami na poziomie tygodni/miesięcy, które GRU skutecznie modeluje

Model GRU, zaimplementowany w bibliotece Keras, posiada dwie równoległe gałęzie wejściowe: sekwencyjną oraz statyczną, które następnie są łączone w jedną sieć gęstą. Architektura została zaprojektowana w taki sposób, aby umożliwić jednoczesne przetwarzanie informacji o przebiegu treningów (dane sekwencyjne) oraz cech opisujących zawodnika i zawody (dane statyczne).

1. **Gałąź sekwencyjna:**
   - Warstwa wejściowa: `Input(shape=(232, 11))`.
   - Warstwa maskująca (`Masking`) – ignoruje dopełnienie 999.0, pozwalając na przetwarzanie sekwencji o różnej długości.
   - Dwukierunkowa warstwa GRU (`Bidirectional(GRU(16, return_sequences=True))`) – analizuje zależności czasowe w obu kierunkach, co pozwala modelowi lepiej uchwycić kontekst treningu.
   - Warstwa `Dropout` (30%) oraz `BatchNormalization` – ograniczają ryzyko przeuczenia i stabilizują proces uczenia.
   - Druga warstwa GRU (`Bidirectional(GRU(16, return_sequences=False))`) – zwraca końcową reprezentację sekwencji jako wektor o stałej długości.
   - Warstwa gęsta (`Dense(32, activation='relu')`) – pozwala wydobyć bardziej złożone wzorce z reprezentacji sekwencji.

2. **Gałąź statyczna:**
   - Warstwa wejściowa: `Input(shape=(12,))` (11 cech statycznych, m.in. zagregowane dane o treningach kolarskich, pływackich i siłowych, a także dystans wyścigu oraz 1 cecha binarna - czy wyścig docelowy jest triathlonem).
   - Warstwa gęsta (`Dense(32, activation='relu')`) z `Dropout(0.3)` przekształca cechy statyczne do wspólnej przestrzeni z danymi sekwencyjnymi.

Wyjścia obu gałęzi są łączone (`concatenate`), a następnie przetwarzane przez kolejne warstwy gęste (`Dense(32, activation='relu')` z `BatchNormalization` i `Dropout`). Ostateczna warstwa wyjściowa (`Dense(1, activation='linear')`) przewiduje przeskalowane tempo biegu (w sekundach na kilometr).

Model został skompilowany z użyciem optymalizatora `Adam` (`learning_rate = 5e-4`) oraz funkcji straty `Mean Absolute Error (MAE)`. Dobór parametrów został poprzedzony serią eksperymentów:

- **Liczba jednostek ukrytych (16)** – zapewnia równowagę między zdolnością modelu do uchwycenia złożonych zależności czasowych a ryzykiem przeuczenia, przy ograniczonym rozmiarze zbioru danych.
- **Dwukierunkowe warstwy GRU** – pozwalają na analizę przebiegu treningu zarówno w przód, jak i wstecz, co zwiększa dokładność identyfikacji wzorców wysiłku.
- **Dropout (0.3)** – redukuje przeuczenie, co jest szczególnie istotne w przypadku małych zbiorów danych oraz powtarzających się wzorców w treningach.
- **Batch Normalization** – przyspiesza uczenie i stabilizuje rozkład aktywacji w głębokiej sieci.
- **Optymalizator Adam** – wybrany ze względu na dobrą stabilność i szybkość zbieżności w problemach regresyjnych. Po przeprowadzeniu licznych eksperymentów współczynnik uczenia `8e-4` okazał się optymalny
- **Funkcja straty (MAE)** – lepiej niż MSE odzwierciedla rzeczywiste błędy w przewidywanym tempie (sekundy/km), ponieważ nie penalizuje nadmiernie pojedynczych dużych odchyleń. Jest to istotne szczególnie w przypadku naszego małego zbioru danych, gdzie nie możemy mieć pewności, że dana aktywność jest wyścigiem. W przypadku użycia metryki MSE duże błędy w przewidywanym wyniku mogą doprowadzić, np. do nadmiernego dopasowania modelu do wartości, które w rzeczywistości są outlierami. To ostatecznie wpłynęłoby negatywnie na ogólną skuteczność modelu.

Model uczono przez 311 epok z `EarlyStopping (patience=50)` oraz `validation_split=0.2`, co umożliwiało automatyczne zatrzymanie uczenia po osiągnięciu optymalnej wartości błędu walidacyjnego. Używano małego batcha o rozmiarze 16. Okazał się on złotym środkiem pod względem odpowiedniej generalizacji modelu oraz odpowiedniej wrażliwości na wartości skrajne.

5.1.12. Wyniki predykcji

Po zakończeniu uczenia model oceniono na zbiorze testowym. Przewidywania (przeskalowane) zostały przekształcone z powrotem do oryginalnych jednostek (sekundy/km) za pomocą wcześniej zapisanego skalera.

Przeliczenie przewidywań tempa na całkowity czas biegu

Model przewidywał średnie tempo zawodnika w sekundach na kilometr (`pace_sec_per_km`). Aby uzyskać ostateczny czas ukończenia wyścigu, wartości te zostały przeliczone na całkowity czas (`total_time`) poprzez pomnożenie przewidywanego tempa przez rzeczywisty dystans biegu w kilometrach (`race_distance_m/1000`), zapisany w trakcie tworzenia sekwencji do metadanych wyścigu.

$$predykowany_czas[s] = predykowane_tempo[s/km] \times dystans[km]$$

Rzeczywiste tempo również zostało przemnożone przez dystans, co pozwoliło na bezpośrednie porównanie wyników modelu z rzeczywistymi czasami uzyskanymi przez zawodników. Oczywiście obliczony w ten sposób rezultat wyścigu nie daje nam nowych informacji o skuteczności modelu, jednak niewątpliwie ułatwia interpretację wyników w kontekście wielkości błędu.

Ewaluacja wyników

Aby uzyskać miary błędów w fizycznie interpretowalnych jednostkach, obliczono:

- **MAE (Mean Absolute Error):** Średni błąd bezwzględny w sekundach na kilometr.
- **RMSE (Root Mean Square Error):** Pierwiastek błędu średniokwadratowego (kara za duże błędy).
- **NRMSE (Normalized RMSE):** RMSE podzielony przez średnią wartość tempa w zbiorze testowym.
- **MAPE (Mean Absolute Percentage Error):** Średni absolutny błąd procentowy.

Dla obu wariantów — tempa i całkowitego czasu — obliczono wymienione miary skuteczności modelu. Zastosowanie tych metryk pozwoliło zweryfikować skuteczność modelu w praktycznym kontekście – jako narzędzia do szacowania czasu ukończenia biegu przez danego zawodnika. W praktyce błędy dla całkowitego czasu utrzymywały się na poziomie zbliżonym do błędów tempa (np. `MAPE` $\approx$ `7%`), co potwierdza stabilność modelu i poprawność przeliczenia między oboma typami predykcji.

5.1.13. Analiza błędów i interpretacja wyników

Ocena skuteczności

Model osiągnął następujące wyniki na zbiorze testowym (58 wyścigów):

Miara błędu	Wartość (dla tempa)	Wartość (dla czasu wyścigu)
MAE (Mean Absolute Error)	0,3 min	4,6 min
RMSE (Root Mean Squared Error)	0,5 min	11,8 min
NRMSE (Normalized RMSE)	0,1	0,23
MAPE (Mean Absolute Percentage Error)	7,34%	7,34 %

Tabela 5.1: Wyniki modelu GRU na zbiorze testowym

Wartość MAE na poziomie 0,3 min/km (4,6 min w kontekście czasu wyścigu) oznacza, że średnio przewidywane tempo różniło się od rzeczywistego o około 18 sekund na każdy kilometr. Dla biegacza amatora, utrzymującego tempo 5:00 min/km (300 s/km), błąd ten stanowi około 7% wartości rzeczywistej, co można uznać za zadowalający poziom dokładności w kontekście prognozowania wydolności i planowania strategii biegu.

Również niski poziom RMSE (0,5 min/km) oraz NRMSE równy 0,1 wskazują na stabilność modelu i brak dużych odchyleń w przewidywaniach. Z kolei MAPE na poziomie 7,34% potwierdza, że błędy względne utrzymują się w akceptowalnych granicach, co oznacza, że model dobrze generalizuje również dla wyścigów o różnych dystansach i tempach. Dla przykładu, z takim MAPE dla biegacza zdolnego przebiec 5 km w 20 minut, model oszacuje jego wynik z dokładnością do około. 1,4 minuty - jest to efekt zdecydowanie zadowalający, lepszy lub porównywalny z tymi proponowanymi w literaturze.

Analiza błędów

Porównanie przewidywanych i rzeczywistych czasów wyścigów dla wybranych zawodników daje nam możliwość lepszej interpretacji błędów modelu. Wyniki w poniższej tabeli pokazują przewidywany czas ze zbioru testowego. Obejmują zarówno krótsze biegi (3–5 km), jak i średnie oraz długie dystanse (21 km, 42 km), co pokazuje zdolność modelu do generalizacji. Znakomita większość predykcji tempa biegu zawodnika nie różni się od prawdziwej wartości o więcej niż 0,2 minuty. Zgodnie z przewidywaniami, najgorsze predykcje otrzymaliśmy dla biegów maratońskich (2 takie biegi w zbiorze testowym). Tutaj błędy predykcji wynoszą odpowiednio 1,8 minuty oraz 1,01 minuty dla tempa i są to zdecydowanie najmniej dokładne predykcje modelu. Warto jednak zauważyć, że nasz zbiór danych zawiera tylko 8 biegów maratońskich. Model nie miał więc szans nauczyć się odpowiednich wzorców dla tak specyficznego biegu, jakim jest maraton. Błędy ujemne i dodatnie występują z podobną częstotliwością, a różnice te mieszczą się w granicy błędu 7% wartości. Oznacza to, że model nie ma tendencji do niedoszacowywania ani przeceniania rzeczywistego czasu, co jest niewątpliwą zaletą. Mimo że największe odchylenia w przewidywaniach zaobserwowano dla wspomnianych maratonów, to w pozostałych przypadkach błędy są podobne zarówno dla krótkich, jak i długich dystansów. Ostatecznie stanowi to o porównywalnej skuteczności modelu dla zróżnicowanych dystansów.

Zawodnik	Dystans [km]	Czas rzeczywisty [min]	Czas przewidziany [min]	Błąd [min]	Błąd tempa [min/km]
athlete_1	10.07	34.92	40.15	+5.23	+0.52
athlete_1	10.82	48.53	48.53	-0.01	-0.00
athlete_11	10.09	49.02	54.30	+5.29	+0.52
athlete_11	6.43	34.45	34.18	-0.27	-0.04
athlete_13	9.46	42.85	43.02	+0.17	+0.02
athlete_13	7.92	34.58	36.72	+2.14	+0.27
athlete_13	9.86	48.43	44.49	-3.95	-0.40
athlete_13	14.20	68.17	66.92	-1.24	-0.09
athlete_13	9.50	50.48	49.28	-1.20	-0.13
athlete_14	5.34	29.05	30.74	+1.69	+0.32
athlete_14	11.02	67.68	63.94	-3.74	-0.34
athlete_14	5.06	28.20	28.01	-0.19	-0.04
athlete_14	21.30	118.80	128.26	+9.46	+0.44
athlete_15	6.13	28.68	23.66	-5.02	-0.82
athlete_15	5.05	19.58	21.72	+2.14	+0.42
athlete_15	4.85	20.00	21.75	+1.75	+0.36
athlete_15	40.42	272.55	345.60	+73.05	+1.81
athlete_16	10.09	49.02	54.30	+5.29	+0.52
athlete_16	6.43	34.45	34.18	-0.27	-0.04
athlete_17	10.01	47.37	46.77	-0.60	-0.06
athlete_17	12.01	57.78	56.42	-1.36	-0.11
athlete_17	8.50	46.37	41.97	-4.40	-0.52
athlete_17	42.39	185.75	228.57	+42.82	+1.01
athlete_18	42.36	205.45	211.48	+6.03	+0.14
athlete_2	5.01	24.13	23.12	-1.01	-0.20
athlete_2	10.02	42.40	44.61	+2.21	+0.22
athlete_2	5.00	23.15	22.60	-0.55	-0.11
athlete_2	4.93	22.38	22.05	-0.33	-0.07
athlete_3	10.04	40.85	42.01	+1.16	+0.12
athlete_3	21.22	94.68	96.63	+1.94	+0.09
athlete_3	10.02	41.03	42.56	+1.52	+0.15
athlete_3	21.20	91.57	103.25	+11.69	+0.55
athlete_4	4.21	16.50	17.97	+1.47	+0.35
athlete_5	3.88	14.73	16.79	+2.06	+0.53
athlete_7	5.11	22.02	22.72	+0.71	+0.14
athlete_7	10.01	44.50	46.13	+1.63	+0.16
athlete_7	10.00	44.90	46.77	+1.87	+0.19
athlete_7	10.01	46.68	46.26	-0.43	-0.04
athlete_8	5.56	26.23	24.64	-1.60	-0.29

Tabela 5.2: Porównanie przewidywanych i rzeczywistych czasów wyścigów dla wybranych zawodników

Interpretacja i ograniczenia

– **Mocne strony:** Model wykorzystuje bogaty kontekst treningowy, nie tylko biegania, oraz uwzględnia charakterystykę indywidualną zawodnika. Bierze pod uwagę tętno maksymalne, tempo maksymalne, predyspozycje szybkościowe i wytrzymałościowe a także ogólne wysportowanie w zakresie sportów wydolnościowych. Dzięki agregacji treningu siłowego, uwzględniona została także sprawność motoryczna. Kolejnym istotnym elementem jest fakt, że model uwzględ-

nia wpływ temperatury na trudność treningu. Sam wyścig docelowy również został dokładniej sparametryzowany w porównaniu z predykcjami modelu maratońskiego - nie tylko możemy tutaj wybrać dystans wyścigu, ale też przewyższenie na trasie.

– **Ograniczenia:** Jakość predykcji jest silnie uzależniona od kompletności i jakości danych wejściowych. W zbiorze danych występowało wiele brakujących wartości, szczególnie w kolumnach takich jak temperatura czy tętno, które musiały być uzupełniane. Niewielki rozmiar zbioru testowego (58 przypadków) utrudnia wyciągnięcie mocnych wniosków statystycznych. Grupa zawodników, od których pozyskane zostały dzienniki treningowe, jest prawdopodobnie niewystarczająco reprezentatywna dla ogółu populacji. Model nie uwzględnia też niektórych potencjalnie istotnych czynników zewnętrznych, takich jak trasa (np. ilość zakrętów, rozmieszczenie podbiegów na trasie), nawierzchnia (np. alfalt, trawa, piasek), inne niż temperatura warunki pogodowe w dniu wyścigu oraz na treningach (np. prędkość wiatru, wilgotność) czy taktyka (bieg z progresją, stałe tempo).

5.1.14. Wnioski

Eksperyment potwierdził wykonalność budowy modelu prognostycznego tempa biegowego na podstawie złożonych, wieloźródłowych danych treningowych. Zaproponowana hybrydowa architektura GRU, łącząca przetwarzanie sekwencyjne i statyczne, okazała się trafnym rozwiązaniem dla problemu o wysokiej złożoności.

W porównaniu z modelem maratońskim, który operował na bardziej jednorodnych danych, obecny model mierzy się z zadaniem znacznie trudniejszym — musi przewidywać wyniki w szerokim zakresie typów wyścigów, obejmujących różne dystanse (od 3 do 42 km) oraz zmienne warunki terenowe i przewyższenia. Pomimo tego uzyskane metryki błędu ($MAPE \approx 7\%$) świadczą o dobrej ogólnej skuteczności i stabilności predykcji. Model trafnie odwzorowuje rzeczywiste relacje między parametrami wysiłku, co potwierdzają niskie błędy bezwzględne w większości przypadków indywidualnych.

Największym ograniczeniem eksperymentu pozostaje rozmiar i struktura zbioru danych — pomimo dużej liczby aktywności, liczba unikalnych zawodników jest stosunkowo mała. Powoduje to, że model może częściowo przeuczać się na indywidualne wzorce treningowe, zamiast generalizować między zawodnikami. Wzbogacenie zbioru o dane od większej liczby biegaczy umożliwiłoby zastosowanie bardziej restrykcyjnych heurystyk identyfikujących aktywności wyścigowe, na przykład:

– ograniczenie analizy do standardowych dystansów (5 km, 10 km, półmaraton, maraton),

– lepsze rozróżnienie między treningami kontrolnymi a startami w zawodach poprzez bardziej rygorystyczną heurystykę klasyfikującą aktywność jako wyścig

W przyszłych pracach szczególnie wartościowe będzie:

1. Zwiększenie liczby uczestników oraz poprawa jakości i kompletności danych.

2. Integracja danych kontekstowych, takich jak profil trasy, pogoda czy poziom zmęczenia.

3. Personalizacja predykcji poprzez fine-tuning modelu dla pojedynczych zawodników.

4. Budowa interfejsu dla użytkownika, z możliwością wgrania własnych danych treningowych oraz uzyskania predykcji

Uzyskane wyniki wskazują, że opracowany model nie tylko skutecznie przewiduje tempo i czas wyścigu, ale również może stanowić podstawę do budowy inteligentnego systemu wspierającego planowanie i analizę startów w biegach masowych.

6. Analiza porównawcza modeli i wnioski końcowe

Przeprowadzone badania wykazały wyraźne różnice w skuteczności obu podejść, co potwierdza hipotezę o komplementarności modeli ogólnych i personalizowanych w prognozowaniu wyników biegowych.

6.1. Porównanie skuteczności modelu ogólnego i personalizowanego

Model ogólny osiągnął NRMSE na poziomie 9.85% przy predykcji czasów maratońskich, co stanowi znaczącą poprawę w porównaniu z klasyczną formułą Riegla (NRMSE 17.95%). Model ten, oparty na architekturze GRU, przetwarzającej sekwencje treningowe kilku tysięcy zawodników, wykazał się dobrą zdolnością do generalizacji na dużej populacji biegaczy. Jego kluczową zaletą jest szeroka zastosowalność przy stosunkowo niewielkich wymaganiach dotyczących danych wejściowych.

Model personalizowany osiągnął wyższą dokładność z MAPE 7.34% przy predykcji wyników na różnych dystansach (3-42 km). Hybrydowa architektura, łącząca przetwarzanie sekwencyjne danych treningowych z cechami statycznymi zawodnika, pozwoliła na uwzględnienie indywidualnych charakterystyk, w tym maksymalnego tętna, doświadczenia wielodyscyplinarnego (triathlon) oraz warunków środowiskowych.

6.2. Porównanie z istniejącymi rozwiązaniami

Wyniki uzyskane w pracy wypadają korzystnie na tle istniejących rozwiązań:

- **Model ogólny (NRMSE 9.85%)** przewyższa dokładność formuły Riegla (NRMSE 17.95%) i jest porównywalny z wynikami modeli proponowanych w literaturze (MAPE 10%) [4]

- **Model personalizowany (MAPE 7.34%)** osiąga lepszą dokładność niż modele zgłaszane w literaturze dla biegów na różnych dystansach [5], porównywalną z nawet najlepszymi modelami ograniczającymi się do maratonu [4]

- Oba modele wykazują podobną skuteczność predykcji w porównaniu do rozwiązań proponowanych w literaturze, przy lepszej generalizacji w kontekście poziomu sportowego zawodników, nie skupiając się wyłącznie na zawodnikach profesjonalnych

6.3. Analiza wpływu cech na dokładność predykcji

Analiza ważności cech w obu modelach ujawniła istotne prawidłowości dotyczące czynników wpływających na wyniki biegowe:

W modelu ogólnym największe znaczenie miały:

- Całkowity dystans treningowy - najbardziej istotny czynnik
- Doświadczenie maratońskie (liczba poprzednich startów)
- Cechy demograficzne (wiek, płeć)

Całkowity czas treningu okazał się zaskakująco mało znaczący

W modelu personalizowanym kluczowymi czynnikami były:

- Tętno maksymalne i średnie jako wskaźniki intensywności
- Charakter wyścigu (czy część triathlonu)
- Dystans i profil trasy docelowego wyścigu
- Historia treningowa z uwzględnieniem innych dyscyplin (kolarstwo, pływanie, trening siłowy)
- Warunki pogodowe (temperatura)

6.4. Ograniczenia badawcze i problemy napotkane

Badania napotkały kilka istotnych ograniczeń metodologicznych:

Ograniczenia danych:

- **Model ogólny**: Brak danych fizjologicznych (tętno), ograniczony zakres czasowy (2019-2020), zależność od jakości urządzeń pomiarowych użytkowników
- **Model personalizowany**: Mała liczebność próby (20 zawodników), brakujące wartości w kluczowych kolumnach, niejednorodność formatów danych z różnych platform

Ograniczenia metodologiczne:

- Identyfikacja wyścigów oparta na heurystykach zamiast weryfikacji zewnętrznej, np. oficjalnego rankingu
- Brak standaryzacji pomiarów między różnymi urządzeniami sportowymi
- Ograniczona możliwość uwzględnienia czynników taktycznych i psychologicznych

Problemy techniczne:

- Konieczność obsługi sekwencji o różnej długości
- Braki wartości w danych fizjologicznych
- Integracja danych z różnych źródeł

6.5. Rekomendacje dla praktyków sportowych

Wyniki badań pozwalają sformułować następujące rekomendacje praktyczne:

Dla biegaczy amatorów:

– Model predykcyjny może służyć do skutecznej wstępnej oceny potencjału zawodnika

– Regularne rejestrowanie treningów w aplikacjach sportowych umożliwia wykorzystanie zaawansowanych modeli predykcyjnych

– Uwzględnienie treningów w innych dyscyplinach poprawia dokładność prognoz

Dla trenerów:

– Model personalizowany może wspierać planowanie strategii wyścigowych

– Monitorowanie tętna maksymalnego jest kluczowe dla oceny intensywności wysiłku

– Uwzględnienie warunków środowiskowych poprawia realistyczność prognoz

Dla organizatorów biegów:

– Modele predykcyjne mogą pomóc w segmentacji uczestników i planowaniu logistyki

– Uwzględnienie profilu trasy w prognozach zwiększa ich praktyczną przydatność

6.6. Kierunki przyszłych badań

Wyniki pracy wskazują na kilka obiecujących kierunków dalszych badań:

Rozszerzenie danych:

– Pozyskanie większych zbiorów danych z weryfikowanymi wynikami wyścigów oraz kompletnymi danymi dotyczącymi tętna, temperatury, a także np. wagi zawodnika

– Integracja danych o nawierzchni, taktyce biegu i warunkach pogodowych

Zastosowania praktyczne:

– Opracowanie interfejsu użytkownika dla automatycznej predykcji na podstawie eksportu danych

– Budowa systemu rekomendacji optymalnego tempa wyścigowego

– Integracja z aplikacjami treningowymi w czasie rzeczywistym

Badania porównawcze:

– Porównanie skuteczności z komercyjnymi narzędziami prognostycznymi

– Badanie wpływu różnych podejść do uzupełniania brakujących danych

– Analiza wrażliwości modeli na zmiany w charakterystyce treningu

6.7. Podsumowanie

Przeprowadzone badania pokazały możliwość budowy skutecznych modeli predykcyjnych wyników biegowych z wykorzystaniem metod głębokiego uczenia. Oba zaproponowane podejścia - ogólne i personalizowane - wykazały przewagę nad tradycyjnymi metodami proponowanymi w literaturze. Model ogólny stanowi praktyczne narzędzie do szybkiej oceny potencjału maratońskiego na podstawie podstawowych danych treningowych, podczas gdy model personalizowany umożliwia dokładniejsze prognozowanie wyników w zróżnicowanych warunkach startowych. Osiągnięcie błędu predykcji na poziomie 7-10% przy uwzględnieniu ograniczonych zbiorów danych wskazuje na duży potencjał tych metod w praktycznych zastosowaniach sportowych.

Praca wnosi wkład w rozwój metod prognozowania wyników sportowych poprzez:

– Opracowanie kompletnych pipeline'ów przetwarzania danych z rzeczywistych źródeł

– Zastosowanie zaawansowanych architektur sieci neuronowych do modelowania danych treningowych

– Identyfikacja kluczowych czynników wpływających na dokładność predykcji

– Praktyczne rekomendacje dla różnych grup użytkowników

Dalszy rozwój opisanych metod, w połączeniu z rosnącą dostępnością danych treningowych, może w przyszłości przyczynić się do powstania zaawansowanych systemów wspomagających trening i starty w sportach wytrzymałościowych.

Bibliografia

[1] L. A. Afonseca, R. N. Watanabe, and M. Duarte, "A worldwide comparison of long-distance running training in 2019 and 2020: associated effects of the covid-19 pandemic," *PeerJ*, vol. 10, p. e13192, Mar. 2022. [Online]. Available: https://doi.org/10.7717/peerj.13192

[2] L. Afonseca, R. N. Watanabe, and M. Duarte, "A public dataset on long-distance running training in 2019 and 2020," 9 2021. [Online]. Available: https://figshare.com/articles/dataset/A_public_dataset_on_long-distance_running_training_in_2019_and_2020/16620238

[3] D. Ruiz-Mayo, E. Pulido, and G. Martınoz, "Marathon performance prediction of amateur runners based on training session data," *Proc Mach Learn Data Min Sports Anal*, vol. 8, 2016.

[4] H. T. El-Kassabi, K. Khalil, and M. A. Serhani, "Deep learning approach for forecasting athletes' performance in sports tournaments," in *Proceedings of the 13th International Conference on Intelligent Systems: Theories and Applications*, ser. SITA'20. New York, NY, USA: Association for Computing Machinery, 2020. [Online]. Available: https://doi.org/10.1145/3419604.3419786

[5] S. Dash, "Win your race goal: A generalized approach to prediction of running performance," *Sports Medicine International Open*, vol. 8, no. continuous publication, 2024.

[6] V. Scheer, "Participation trends of ultra endurance events," *Sports Medicine and Arthroscopy Review*, vol. 27, pp. 3–7, 01 2019.

[7] Z. Jarlaczyńska, "Activities garmin," https://www.kaggle.com/datasets/zuskakluska/activities-garmin, 2025, kaggle dataset.

[8] ——, "Strava activities," https://www.kaggle.com/datasets/zuskakluska/strava-activities, 2025, kaggle dataset.

[9] P. S. Riegel, "Athletic records and human endurance: a time-vs.-distance equation describing world-record performances may be used to compare the relative endurance capabilities of various groups of people," *American Scientist*, vol. 69, no. 3, pp. 285–290, 1981.

[10] L. Lerebourg, D. Saboul, M. Clemencon, and J. B. Coquart, "Prediction of marathon performance using artificial intelligence," *International Journal of Sports Medicine*, vol. 44, no. 05, pp. 352–360, 2023.

[11] M. Thuany, T. N. Gomes, and M. Almeida, “Is there any difference between "amateur"and "recreational"runners? a latent class analysis,” *Motriz. Revista de Educação Física*, 12 2020.

[12] T. Perumal, N. Mustapha, R. Mohamed, and F. M. Shiri, “A comprehensive overview and comparative analysis on deep learning models,” *Journal on Artificial Intelligence*, vol. 6, no. 1, p. 301–360, 2024. [Online]. Available: http://dx.doi.org/10.32604/jai.2024.054314

[13] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[14] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” 12 2014.

[15] S. Seiler, “Training intensity distribution,” *Endurance Training Science and Practice. Basque Country: Inigo Mujika SLU*, pp. 29–41, 2012.

[16] M. Kenneally, A. Casado, and J. Santos-Concejero, “The effect of periodization and training intensity distribution on middle-and long-distance running performance: a systematic review,” *International journal of sports physiology and performance*, vol. 13, no. 9, pp. 1114–1121, 2018.

[17] W. Li, “Evaluation of running intensity and fatigue degree based on human physiological information,” *Mobile Information Systems*, vol. 2022, no. 1, p. 6488312, 2022.

[18] T. Haugen, O. Sandbakk, S. Seiler, and E. Tønnessen, “The training characteristics of world-class distance runners: An integration of scientific literature and results-proven practice,” *Sports Medicine - Open*, vol. 8, pp. 1–18, 04 2022.

[19] L. A. Afonseca, R. N. Watanabe, and M. Duarte, “A worldwide comparison of long-distance running training in 2019 and 2020: associated effects of the covid-19 pandemic,” *PeerJ*, vol. 10, p. e13192, 2022.

[20] Z. Jarlaczyńska, “Marathon only race predictior,” https://www.kaggle.com/code/zuskakluska/intelligent-marathon-race-predictions, 2024, kaggle notebook.

[21] ——, “Race predictor 2,” https://www.kaggle.com/code/zuskakluska/race-predictior-2, 2025, kaggle notebook.

[22] J. Friel, *Triatlon. Biblia treningu*. Warszawa: Buk Rower, 2012.